TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN

HỒ ĐẠI VĨ

MSSV: 234822

LỚP: DH23TIN05

CÔNG CỤ DỰ ĐOÁN MẮC BỆNH TIM MẠCH

ĐỒ ÁN CƠ SỞ

Ngành: Công Nghệ Thông Tin

Mã số ngành: 7480201

03/2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ

KHOA CÔNG NGHỆ THÔNG TIN

Hồ Đại Vĩ

MSSV: 234822

LỚP: DH23TIN05

CÔNG CỤ DỰ ĐOÁN MẮC BỆNH TIM MẠCH

ĐỒ ÁN CƠ SỞ

Ngành: Công Nghệ Thông Tin

Mã số ngành: 7480201

GIẢNG VIÊN HƯỚNG DẪN

ThS. TRẦN VĂN THIỆN

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành đến thầy **ThS. Trần Văn Thiện**, giảng viên Khoa Công nghệ thông tin - trường Đại học Nam Cần Thơ đã hướng dẫn để chúng em hoàn thành đồ án này.

Em cũng xin chân thành cảm ơn các thầy cô trong trường đại học Nam Cần Thơ nói chung và các thầy cô khoa công nghệ thông tin nói riêng đã dạy em những kiến thức về các môn đại cương cũng như các môn chuyên ngành, giúp em có được cơ sở lý thuyết vững vàng và tạo điều kiện giúp đỡ em trong suốt quá trình học tập.

Mặc dù, chúng em đã có rất nhiều cố gắng nỗ lực để hoàn thành đồ án nhưng vẫn không tránh khỏi những thiếu sót. Kính mong nhận được sự đóng góp ý kiến của quý thầy cô.

Cần Thơ, ngày tháng năm 2026

Người thực hiện 1

Hồ Đại Vĩ

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

Cần Thơ, ngày .... tháng .... năm 2023

Giảng Viên Hướng Dẫn

ThS. Trần Văn Thiện

MỤC LỤC

CHƯƠNG 1: GIỚI THIỆU 1
1.1. Lý do chọn đề tài: 1
1.2. Mục tiêu đề tài: 3
1.3. Mục tiêu nghiên cứu 3
1.4. Phạm vi và phương pháp nghiên cứu 4
1.4.1. Phạm vi nghiên cứu 4
1.4.2. Phương pháp nghiên cứu 4
1.5. Ý nghĩa khoa học và thực tiễn 5
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT 6
2.1.Tổng quan về AI và Machine Learning trong y tế 6
2.1.1. Định nghĩa và phân loại 6
2.1.2. Vì sao Machine Learning phù hợp với bài toán tim mạch? 6
2.2. Mô tả dữ liệu chẩn đoán 7
2.3. Các thuật toán Machine Learning sử dụng: 7
2.3.1. Logistic Regression (Hồi quy Logistic): 7
2.3.2. XGBoost (Extreme Gradient Boosting): 9
2.4. Các chỉ số đánh giá mô hình: 10
2.4.1. Ma trận nhầm lẫn: 10
2.4.2. Hiệu chỉnh xác suất (Calibration) 12
2.5. Nguồn Dữ Liệu Huấn Luyện — Kaggle và Hugging Face 12
2.6. Quy Trình Xây Dựng Mô Hình AI — Từ Dữ Liệu Đến Triển Khai 13
2.6.1. Tổng quan Pipeline 13
2.6.2. Làm sạch dữ liệu 14
2.6.3. Phân chia dữ liệu và chuẩn hóa 14
2.6.4. So sánh các mô hình Machine Learning 14
2.6.5. Hiệu chỉnh xác suất dự đoán 15
2.6.6. Đánh giá mô hình 15
2.6.7. Đóng gói mô hình 16
2.7. Cơ Sở Dữ Liệu 17
2.7.1. Khái Niệm Cơ Sở Dữ Liệu Quan Hệ 17
2.7.2. Microsoft SQL Server 17

2.7.3. SQL (Structured Query Language) 18
CHƯƠNG 3: Phân Tích & Thiết Kế Hệ Thống 19
3.1. Mô tả bộ dữ liệu UCI Heart Disease (Dataset): 19
3.1.1. Nguồn gốc và lịch sử 19
3.1.2. Ý nghĩa y khoa của từng thuộc tính 19
3.2. Tiền xử lý dữ liệu (Data Preprocessing): 21
3.2.1. Xử lý giá trị thiếu (Missing Values) 21
3.2.2. Xử lý giá trị ngoại lai (Outlier) 21
3.2.3. Xử lý biến phân loại 21
3.2.4. Chuẩn hóa dữ liệu (Feature Scaling) 22
3.3. Yêu cầu hệ thống 23
3.3.1 Yêu Cầu Chức Năng 23
3.3.2 Yêu Cầu Phi Chức Năng 25
3.4. Thiết kế cơ sở dữ liệu 26
3.5. Thiết Kế API 28
3.6. Luồng Nghiệp Vụ Chính 30
3.6.1 Luồng đăng nhập 30
3.6.2 Luồng dự đoán nguy cơ bệnh tim (luồng chính) 30
3.6.3. Luồng quên mật khẩu (OTP) 31
3.7. Sơ Đồ Use Case 32
3.8. Sơ Đồ ERD (Entity-Relationship Diagram) 33
3.9. Sơ Đồ DFD (Data Flow Diagram) 33
3.9.1. DFD Level 0 — Context Diagram 33
3.9.2. DFD Level 1 — Các Tiến Trình Chính 34
CHƯƠNG 4: GIAO DIỆN HỆ THỐNG 35
4.1. Trang Đăng Nhập / Đăng Ký 35
4.2. Dashboard Tổng Quan: 35
4.3. Trang Lịch Sử Chẩn Đoán 36
4.4. Trang Báo Cáo 36
4.5. Trang Phân Tích 37
4.6. Trang Cá Nhân Hóa 37
CHƯƠNG 5: KẾT LUẬN 38
5.1. Kết Quả Đạt Được 38

5.1.1. Kết Quả Đạt Được 38
5.1.2. Về mô hình học máy 38
5.1.3. Về hệ thống Backend 38
5.1.4. Về hệ thống Frontend 39
5.1.5. Về giám sát và vận hành 39
5.1.6. Về triển khai 39
5.2. Hạn Chế Của Đề Tài 39
5.2.1. Về độ chính xác của mô hình 40
5.2.2. Về dữ liệu đầu vào 40
5.2.3. Về khả năng giải thích của mô hình 40
5.2.4. Về bảo mật và tuân thủ 40
5.3. Hướng Phát Triển 41
5.3.1. Nâng cao mô hình AI 41
5.3.2. Mở rộng dữ liệu đầu vào 41
5.3.3. Cải thiện trải nghiệm sử dụng 42
5.3.4. Tăng cường bảo mật 42
5.3.5. Kiến trúc và vận hành hệ thống 42
TÀI LIỆU THAM KHẢO 43

DANH SÁCH BẢNG

Tên bảng	Trang
Bảng 2.1 Mô tả dữ liệu chẩn đoán	7
Bảng 2.2 Ma trận so sánh	10
Bảng 2.3 So sánh các mô hình Machine Learning	15
Bảng 2.4 Đánh giá mô hình	15
Bảng 2.5 Phân tầng nguy cơ	17
Bảng 3.1 Phân tầng nguy cơ	23
Bảng 3.2 Dự đoán nguy cơ tim mạch	23
Bảng 3.3 Quản lý lịch sử chẩn đoán	24
Bảng 3.4 Giám sát hệ thống	24
Bảng 3.5 Quản trị (Admin)	24
Bảng 3.6 Bảng hiệu năng	25
Bảng 3.7 Bảo mật	25
Bảng 3.8 Độ tin cậy & dự phòng	25
Bảng 3.9 Thiết kế cơ sở dữ liệu	26
Bảng 3.10 Bảng điểm nguy cơ	27
Bảng 3.11 Bảng tài khoản	27
Bảng 3.12 Bảng báo cáo	27
Bảng 3.13 Bảng endpoints	28
Bảng 3.14 Bảng authentication	29
Bảng 3.15 Bảng dự đoán	29
Bảng 3.16 Chẩn đoán	29
Bảng 3.17 Giám sát hệ thống	30

DANH SÁCH HÌNH

Tên hình	Trang
Hình 3.1: Sơ đồ Use Case	32
Hình 3.2: Sơ đồ ERD	33
Hình 3.3: Sơ đồ DFD cấp 0	33
Hình 3.4: Sơ đồ DFD cấp 1	34
Hình 4.1: Giao diện đăng nhập	35
Hình 4.2: Dashboard tổng quan	35
Hình 4.3: Trang lịch sử chẩn đoán	36
Hình 4.4: Trang báo cáo	36
Hình 4.5: Trang phân tích	37
Hình 4.6: Trang phân tích	37

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Ý nghĩa
AI	Artificial Intelligence — Trí tuệ nhân tạo
ML	Machine Learning — Học máy
CVD	Cardiovascular Diseases — Bệnh tim mạch
WHO	World Health Organization — Tổ chức Y tế Thế giới
ECG	Electrocardiogram — Điện tâm đồ
XGBoost	Extreme Gradient Boosting — Thuật toán tăng cường gradient
LR	Logistic Regression — Hồi quy Logistic
RF	Random Forest — Rừng ngẫu nhiên
TP	True Positive — Dự đoán đúng (có bệnh)
TN	True Negative — Dự đoán đúng (không bệnh)
FP	False Positive — Dự đoán sai (báo nhầm)
FN	False Negative — Dự đoán sai (bỏ sót)
ROC	Receiver Operating Characteristic — Đường cong đánh giá mô hình
AUC	Area Under Curve — Diện tích dưới đường cong
API	Application Programming Interface — Giao diện lập trình ứng dụng
JSON	JavaScript Object Notation — Định dạng dữ liệu JSON
CSV	Comma-Separated Values — Tệp dữ liệu dạng bảng
IQR	Interquartile Range — Khoảng tứ phân vị
NaN	Not a Number — Giá trị không hợp lệ
CV	Cross Validation — Kiểm định chéo
CI	Confidence Interval — Khoảng tin cậy

UCI	University of California, Irvine — Nguồn dữ liệu chuẩn
RDBMS	Relational Database Management System — Hệ quản trị CSDL quan hệ
SQL	Structured Query Language — Ngôn ngữ truy vấn có cấu trúc
T-SQL	Transact-SQL — Mở rộng của SQL trong SQL Server
ACID	Atomicity, Consistency, Isolation, Durability — Tính chất giao dịch
KPI	Key Performance Indicator — Chỉ số đánh giá hiệu suất
UI	User Interface — Giao diện người dùng
UX	User Experience — Trải nghiệm người dùng

CHƯƠNG 1: GIỚI THIỆU

1.1. Lý do chọn đề tài:

1.1.1. Thực trạng bệnh tim mạch trên thế giới

Bệnh tim mạch (Cardiovascular Diseases — CVD) từ lâu đã được Tổ chức Y tế Thế giới (WHO) xác định là nguyên nhân gây tử vong số một toàn cầu. Theo báo cáo thống kê năm 2023 của WHO, ước tính có khoảng 17,9 triệu người tử vong mỗi năm do các bệnh liên quan đến tim mạch, chiếm tới 32% tổng số ca tử vong trên toàn thế giới. Trong số đó, nhồi máu cơ tim và đột quỵ chiếm tỷ trọng lớn nhất, lần lượt là 85% tổng số ca tử vong do tim mạch.

Đáng chú ý, phần lớn các trường hợp tử vong do bệnh tim mạch đều có thể được phòng ngừa nếu được phát hiện và can thiệp sớm. Các yếu tố nguy cơ như tăng huyết áp, rối loạn lipid máu, đái tháo đường, béo phì, hút thuốc lá và ít vận động thể chất đã được y học hiện đại xác định rõ ràng và có thể đo lường, theo dõi thông qua các chỉ số lâm sàng. Tuy nhiên, thách thức lớn nhất không nằm ở việc thu thập dữ liệu mà ở khả năng phân tích tổng hợp đa chiều — một lĩnh vực mà trí tuệ nhân tạo đang chứng tỏ ưu thế vượt trội so với phương pháp đánh giá truyền thống.

Các nước phát triển như Hoa Kỳ, Anh và Nhật Bản đã triển khai hệ thống sàng lọc tim mạch dựa trên AI trong các cơ sở y tế lớn từ khá sớm. Nghiên cứu của Attia và cộng sự (2019) công bố trên tạp chí Nature Medicine cho thấy mô hình học sâu phân tích ECG có thể phát hiện nhịp tim bất thường với độ chính xác lên đến 93,7%, vượt trội so với bác sĩ chuyên khoa tim mạch. Điều này đặt ra một câu hỏi quan trọng cho giới học thuật và y tế tại Việt Nam: làm thế nào để ứng dụng những thành tựu AI vào bối cảnh y tế trong nước?

1.1.2. Thực trạng bệnh tim mạch tại Việt Nam

Tại Việt Nam, xu hướng mắc bệnh tim mạch đang gia tăng nhanh chóng và đang trở thành gánh nặng lớn đối với hệ thống y tế quốc gia. Theo số liệu của Hội Tim mạch học Việt Nam, bệnh tim mạch là nguyên nhân gây tử vong hàng đầu, chiếm khoảng 33% tổng số ca tử vong tại Việt Nam mỗi năm — tương đương khoảng 200.000 người. Đáng báo động hơn, độ tuổi mắc bệnh đang ngày càng trẻ hóa, xuất hiện ngay cả ở người dưới 40 tuổi do lối sống hiện đại với chế độ ăn nhiều chất béo, ít vận động và căng thẳng công việc.

Hệ thống y tế Việt Nam đang đối mặt với ba thách thức lớn trong việc đối phó với bệnh tim mạch. Thứ nhất, tỷ lệ bác sĩ chuyên khoa tim mạch so với dân số còn thấp, đặc biệt ở các tỉnh thành nhỏ và vùng nông thôn. Thứ hai,

chi phí xét nghiệm và chẩn đoán chuyên sâu (chụp mạch vành, siêu âm tim doppler) còn cao so với thu nhập trung bình của người dân. Thứ ba, tỷ lệ người dân chủ động khám sức khỏe định kỳ còn thấp, dẫn đến nhiều trường hợp bệnh được phát hiện muộn khi đã có biến chứng nghiêm trọng.

Trong bối cảnh đó, việc xây dựng một công cụ sàng lọc nguy cơ tim mạch hỗ trợ bác sĩ có ý nghĩa thực tiễn rất cao. Một công cụ như vậy không thay thế bác sĩ chuyên khoa, nhưng có thể giúp các bác sĩ đa khoa, y tá hoặc nhân viên y tế tuyến cơ sở nhanh chóng xác định bệnh nhân có nguy cơ cao cần được chuyển khám chuyên sâu — từ đó tối ưu hóa việc sử dụng nguồn lực y tế vốn còn hạn chế.

1.1.3 Vai trò của AI trong y tế hiện đại

Trí tuệ nhân tạo đang tạo ra một bước chuyển mạnh mẽ trong lĩnh vực y tế, với tốc độ phát triển nhanh hơn nhiều so với các công nghệ trước đây. Theo báo cáo của McKinsey Global Institute (2022), quy mô thị trường AI y tế toàn cầu đã đạt khoảng 11 tỷ USD vào năm 2021 và dự kiến chạm mốc 67 tỷ USD vào năm 2027, tương ứng với tốc độ tăng trưởng kép hơn 40% mỗi năm. Con số này phản ánh không chỉ tiềm năng kinh tế mà còn cho thấy mức độ quan tâm và đầu tư ngày càng lớn vào việc ứng dụng AI trong chăm sóc sức khỏe.

Trong lĩnh vực chẩn đoán hình ảnh, AI đã ghi nhận nhiều kết quả ấn tượng. Một nghiên cứu công bố trên Nature (2020) cho thấy mô hình của Google Health có thể phát hiện ung thư vú từ ảnh mammogram với độ chính xác vượt qua cả nhóm bác sĩ chuyên khoa trong một số tiêu chí đánh giá. Bên cạnh đó, các hệ thống như IBM Watson for Oncology hay Microsoft InnerEye đang được triển khai để hỗ trợ bác sĩ trong việc lập kế hoạch điều trị, đặc biệt trong ung thư học, góp phần cá thể hóa phác đồ cho từng bệnh nhân.

Đối với bệnh tim mạch, AI được ứng dụng xuyên suốt nhiều giai đoạn trong quy trình chẩn đoán và điều trị. Từ việc phân tích tín hiệu ECG tự động, đánh giá chức năng tim qua siêu âm, đến dự đoán nguy cơ biến cố tim mạch dựa trên dữ liệu lâm sàng, các mô hình học máy đang dần trở thành công cụ hỗ trợ quan trọng. Thậm chí, một số hệ thống còn tham gia vào việc tối ưu hóa lịch trình phẫu thuật tim, giúp nâng cao hiệu quả vận hành trong bệnh viện.

Trong bối cảnh hệ thống y tế chịu áp lực lớn sau đại dịch COVID-19, việc mở rộng năng lực chẩn đoán mà không phụ thuộc hoàn toàn vào việc tăng nhân lực đang trở thành yêu cầu cấp thiết. AI, vì vậy, được xem là một trong những giải pháp khả thi nhất.

Hệ thống CardioPredict AI được phát triển trong đề tài này thuộc nhóm các hệ thống hỗ trợ ra quyết định lâm sàng.Đây là hướng tiếp cận có tính ứng dụng cao trong thực tế, do không đòi hỏi hạ tầng thiết bị phức tạp hay chi phí đầu tư lớn, đồng thời có thể triển khai linh hoạt trên nền tảng web, phù hợp với điều kiện của nhiều cơ sở y tế hiện nay.

1.2. Mục tiêu đề tài:

Đề tài hướng đến các mục tiêu cụ thể sau:

Mục tiêu chính: Xây dựng một ứng dụng web có khả năng dự đoán nguy cơ mắc bệnh tim mạch của bệnh nhân dựa trên 13 chỉ số lâm sàng, sử dụng mô hình Machine Learning được huấn luyện trên bộ dữ liệu chuẩn quốc tế.

Mục tiêu ứng dụng:

Cung cấp giao diện người dùng trực quan, thân thiện với nhân viên y tế.

Tích hợp hệ thống quản lý và cá nhân hóa theo sở thích người dùng.

Lưu trữ lịch sử chẩn đoán và cung cấp báo cáo thống kê theo thời gian.

Triển khai hệ thống giám sát vận hành đảm bảo độ tin cậy.

Tuân thủ các chuẩn mực AI y tế: báo cáo công bằng, khoảng tin cậy, độ bất định.

1.3. Mục tiêu nghiên cứu

Đề tài này hướng đến những mục tiêu rõ ràng, dễ hiểu và có thể đánh giá được như sau:

Mục tiêu khoa học:

Tìm hiểu và đánh giá khả năng dự đoán của mô hình XGBoost trong việc xác định nguy cơ bệnh tim mạch, dựa trên các chỉ số như độ chính xác và khả năng dự đoán đúng.

Xây dựng một quy trình hoàn chỉnh để huấn luyện mô hình, bao gồm các bước: làm sạch dữ liệu, chọn những thông tin quan trọng, huấn luyện mô hình và kiểm tra kết quả.

Nghiên cứu cách giúp mô hình "giải thích được" kết quả dự đoán (tại sao dự đoán như vậy), đồng thời đánh giá mức độ tin cậy của dự đoán, để phù hợp hơn khi áp dụng trong lĩnh vực y tế.

Mục tiêu kỹ thuật:

Xây dựng một hệ thống web hoàn chỉnh, bao gồm backend sử dụng Flask và frontend sử dụng React, tích hợp mô hình AI XGBoost với độ chính xác đạt tối thiểu 94.2% trên tập dữ liệu kiểm tra.

Thiết kế cơ sở dữ liệu để lưu trữ thông tin người dùng và lịch sử dự đoán, đảm bảo hoạt động ổn định và dễ mở rộng khi triển khai thực tế.

Xây dựng các chức năng cơ bản của hệ thống như nhập dữ liệu bệnh nhân, thực hiện dự đoán và hiển thị kết quả một cách rõ ràng, dễ sử dụng cho người dùng.

1.4. Phạm vi và phương pháp nghiên cứu

1.4.1. Phạm vi nghiên cứu

Phạm vi đề tài

Đề tài được thực hiện trong phạm vi cụ thể như sau:

Về dữ liệu:
Sử dụng bộ dữ liệu UCI Heart Disease (Cleveland), đây là bộ dữ liệu phổ biến trong nghiên cứu về tim mạch. Bộ dữ liệu gồm 303 mẫu, với 13 thông tin lâm sàng (như tuổi, huyết áp, cholesterol,…) và 1 kết quả phân loại (có hoặc không mắc bệnh tim).

Về thuật toán:
Đề tài sử dụng phương pháp Machine Learning truyền thống, cụ thể là mô hình XGBoost. Không sử dụng Deep Learning vì dữ liệu không đủ lớn để đạt hiệu quả tốt.

Về hệ thống:
Xây dựng một ứng dụng web chạy trên máy chủ, người dùng truy cập thông qua trình duyệt. Không phát triển trên điện thoại hoặc các thiết bị phần cứng khác.

Về người dùng:
Hệ thống được thiết kế hướng đến nhân viên y tế như bác sĩ hoặc y tá để hỗ trợ trong quá trình đánh giá nguy cơ bệnh tim, không dành cho bệnh nhân sử dụng trực tiếp.

1.4.2. Phương pháp nghiên cứu

Đề tài sử dụng cách tiếp cận kết hợp giữa tìm hiểu lý thuyết và thực hành:

Nghiên cứu tài liệu:
Tìm hiểu các tài liệu, bài báo và nghiên cứu liên quan đến việc ứng dụng Machine Learning trong dự đoán bệnh tim. Đồng thời xem xét các cách đánh giá mô hình thường dùng trong lĩnh vực y tế.

Thực nghiệm:
Xây dựng và huấn luyện mô hình XGBoost trên dữ liệu đã có. Sau đó đánh giá hiệu quả của mô hình bằng cách chia dữ liệu thành nhiều phần để kiểm tra (cross-validation), đồng thời phân tích mức độ quan trọng của từng đặc trưng trong việc dự đoán.

Phát triển dự án:
Xây dựng hệ thống web để tích hợp mô hình AI, bao gồm backend và frontend. Quá trình phát triển được thực hiện theo từng bước nhỏ để dễ kiểm soát và cải thiện, đồng thời kiểm tra hoạt động của các chức năng để đảm bảo hệ thống chạy ổn định.

1.5. Ý nghĩa khoa học và thực tiễn

Ý nghĩa khoa học:

Đề tài xây dựng được một quy trình hoàn chỉnh, từ xử lý dữ liệu ban đầu cho đến triển khai thành một hệ thống thực tế. Một điểm quan trọng là việc áp dụng phương pháp hiệu chỉnh xác suất dự đoán. Điều này giúp kết quả của mô hình phản ánh đúng hơn khả năng mắc bệnh trong thực tế, thay vì chỉ cho ra con số mang tính tương đối. Trong lĩnh vực y tế, sự chính xác của xác suất này rất quan trọng vì nó có thể ảnh hưởng trực tiếp đến quyết định chẩn đoán và điều trị của bác sĩ.

Ý nghĩa thực tiễn:

Hệ thống có thể được sử dụng tại các phòng khám hoặc bệnh viện tuyến dưới, nơi chưa có bác sĩ chuyên khoa tim mạch. Nhờ đó, nhân viên y tế có thể sàng lọc ban đầu và xác định bệnh nhân nào có nguy cơ cao để chuyển lên tuyến trên kịp thời. Điều này giúp giảm tải cho các bệnh viện lớn và nâng cao hiệu quả khám chữa bệnh.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1.Tổng quan về AI và Machine Learning trong y tế

2.1.1. Định nghĩa và phân loại

Trí tuệ nhân tạo (AI) là một lĩnh vực của khoa học máy tính, tập trung vào việc tạo ra các hệ thống có thể thực hiện những công việc mà trước đây cần đến con người, như nhận diện hình ảnh, hiểu ngôn ngữ, suy luận và đưa ra quyết định.

Machine Learning (ML), hay còn gọi là học máy, là một phần của AI. Điểm đặc biệt của ML là máy tính có thể "học" từ dữ liệu. Thay vì phải lập trình từng quy tắc cụ thể, người phát triển chỉ cần cung cấp dữ liệu, từ đó mô hình sẽ tự tìm ra quy luật và sử dụng những quy luật này để đưa ra dự đoán.

Trong lĩnh vực y tế, Machine Learning thường được chia thành ba loại chính:

Học có giám sát (Supervised Learning):
Mô hình được học từ dữ liệu đã có sẵn kết quả đúng (có nhãn). Ví dụ: dự đoán một người có mắc bệnh tim hay không dựa trên dữ liệu sức khỏe. Đây là phương pháp được sử dụng trong đề tài này.

Học không giám sát (Unsupervised Learning):
Mô hình tự tìm ra các nhóm hoặc mối liên hệ trong dữ liệu mà không có sẵn kết quả đúng. Ví dụ: phân nhóm bệnh nhân có đặc điểm giống nhau hoặc phát hiện các trường hợp bất thường.

Học tăng cường (Reinforcement Learning):
Mô hình học thông qua việc thử và sai khi tương tác với môi trường. Ví dụ: hỗ trợ robot trong phẫu thuật hoặc tối ưu hóa kế hoạch điều trị theo thời gian.

2.1.2. Vì sao Machine Learning phù hợp với bài toán tim mạch?

Trong thực tế, bác sĩ thường đánh giá nguy cơ bệnh tim dựa trên kinh nghiệm và một số thang điểm có sẵn như Framingham Risk Score. Tuy nhiên, cách này vẫn có một số hạn chế:

Chỉ sử dụng một số ít yếu tố (khoảng 5–7 thông tin), trong khi dữ liệu bệnh nhân thực tế nhiều và đa dạng hơn.

Giả định mối quan hệ giữa các yếu tố là đơn giản (tuyến tính), trong khi thực tế có thể phức tạp hơn nhiều.

Khó cập nhật hoặc thay đổi khi có thêm dữ liệu mới.

Machine Learning giúp khắc phục những điểm này:

Có thể xử lý cùng lúc nhiều thông tin khác nhau của bệnh nhân và hiểu được các mối quan hệ phức tạp giữa chúng.

Có khả năng tự tìm ra những quy luật trong dữ liệu mà con người có thể chưa nhận ra.

Khi có thêm dữ liệu mới, mô hình có thể được huấn luyện lại để cải thiện độ chính xác.

2.2. Mô tả dữ liệu chẩn đoán

STT	**Ký hiệu**	**Tên đầy đủ**	**Ý nghĩa**
1	**age**	Tuổi	Tuổi bệnh nhân (năm)
2	**sex**	Giới tính	0 = Nữ, 1 = Nam
3	**cp**	Loại đau ngực	0: Không triệu chứng, 1: Điển hình, 2: Không điển hình, 3: Không phải angina
4	**trestbps**	Huyết áp nghỉ	mmHg
5	**chol**	Cholesterol	mg/dL
6	**fbs**	Đường huyết lúc đói > 120 mg/dL	0 = Không, 1 = Có
7	**restecg**	Kết quả ECG nghỉ	0: Bình thường, 1: Bất thường ST-T, 2: Phì đại thất trái
8	**thalach**	Nhịp tim tối đa khi gắng sức	bpm
9	**exang**	Đau thắt ngực khi gắng sức	0 = Không, 1 = Có
10	**oldpeak**	ST Depression	Đơn vị mm
11	**slope**	Độ dốc đoạn ST	0: Dốc lên, 1: Bằng phẳng, 2: Dốc xuống
12	**ca**	Số mạch máu chính bị tổn thương	0–3 (qua chụp huỳnh quang)
13	**thal**	Thalassemia	1: Khiếm khuyết cố định, 2: Bình thường, 3: Khiếm khuyết hồi phục

Bảng 2.1 Mô tả dữ liệu chẩn đoán

2.3. Các thuật toán Machine Learning sử dụng:

2.3.1. Logistic Regression (Hồi quy Logistic):

Nền tảng toán học (viết dễ hiểu):

Logistic Regression là một thuật toán dùng để **dự đoán xác suất** một người có mắc bệnh hay không.

Nó sử dụng công thức:

$$P(y=1 \mid x)=\frac{1}{1+e^{-(w^T x+b)}}$$

Hiểu đơn giản:

Mô hình sẽ lấy các thông tin đầu vào (tuổi, huyết áp, cholesterol,…)

Mỗi thông tin có một "mức độ ảnh hưởng" riêng (gọi là trọng số)

Sau khi tính toán, mô hình đưa ra một **giá trị từ 0 đến 1**

Gần 1 → nguy cơ mắc bệnh cao

Gần 0 → nguy cơ thấp

Trong quá trình huấn luyện, mô hình sẽ tự điều chỉnh các trọng số sao cho dự đoán càng gần với thực tế càng tốt.

Tham số quan trọng:

C (regularization):
Giúp kiểm soát việc mô hình có học quá chi tiết dữ liệu hay không

C nhỏ → mô hình đơn giản hơn → ít bị sai lệch

C lớn → mô hình linh hoạt hơn nhưng dễ bị "học quá mức"
→ Trong đề tài chọn **C = 1.0** để cân bằng

Ưu điểm:

Dễ hiểu và dễ giải thích kết quả

Chạy nhanh, không tốn nhiều tài nguyên

Kết quả trả về là xác suất → rất phù hợp trong y tế

Hoạt động tốt với dữ liệu đơn giản

Nhược điểm:

Không xử lý tốt các mối quan hệ phức tạp giữa nhiều yếu tố

Dễ bị ảnh hưởng nếu các dữ liệu đầu vào có liên quan chặt chẽ với nhau

Cần xử lý dữ liệu tốt thì mới đạt hiệu quả cao

Ứng dụng trong đề tài:

Logistic Regression được dùng làm **mô hình cơ bản để so sánh**.

Độ chính xác của LR trên bài toán tim mạch thường đạt 78-82%, phản ánh mức giới hạn của mô hình tuyến tính với dữ liệu y tế có nhiều tương tác phi tuyến.

2.3.2. XGBoost (Extreme Gradient Boosting):

Nguyên lý hoạt động Gradient Boosting:

XGBoost là một thuật toán mạnh, hoạt động theo cách học từ sai lầm của chính nó.

Cụ thể:

Mô hình không chỉ tạo một cây quyết định duy nhất

Mà tạo ra nhiều cây liên tiếp nhau

Mỗi cây mới sẽ tập trung sửa những lỗi mà các cây trước đã dự đoán **sai.**

Quá trình này có thể hiểu qua công thức:

$$F_t(x)=F_{t-1}(x)+\eta \cdot h_t(x)$$

Hiểu đơn giản:

Kết quả cuối cùng = kết quả trước đó + phần cải thiện mới

η (learning rate) giúp kiểm soát việc học nhanh hay chậm

Nhỏ → học chậm nhưng ổn định

Lớn → học nhanh nhưng dễ **sai.**

Cài đặt trong đề tài:

Mô hình XGBoost được sử dụng với các tham số:

n_estimators = 300 → số lượng cây

max_depth = 4 → độ sâu mỗi cây (giữ vừa phải để tránh phức tạp)

learning_rate = 0.05 → học chậm để ổn định hơn

subsample = 0.85 → dùng 85% dữ liệu mỗi lần học

colsample_bytree = 0.85 → dùng 85% đặc **trưng.**

Cách chọn này giúp mô hình:

Học từ từ

Giảm nguy cơ bị "học quá mức" (overfitting)**.**

Ưu điểm:

Cho kết quả rất tốt với dữ liệu dạng bảng (như dữ liệu bệnh nhân)

Tự xử lý được dữ liệu thiếu (không cần xử lý trước quá nhiều)

Có cơ chế giúp tránh bị học sai lệch

Tốc độ xử lý nhanh, tối ưu tốt

Được sử dụng rất phổ biến trong thực tế và nghiên **cứu.**

Nhược điểm:

Có nhiều tham số → cần chỉnh để đạt kết quả tốt

Nếu chọn sai learning rate hoặc số cây → dễ bị sai lệch

Khó giải thích hơn so với các mô hình đơn giản

Vẫn có thể bị overfitting nếu không thiết lập hợp **lý.**

2.4. Các chỉ số đánh giá mô hình:

Để biết mô hình dự đoán tốt hay không, cần sử dụng các chỉ số đánh giá. Dưới đây là những chỉ số quan trọng, được trình bày theo cách dễ hiểu.

2.4.1. Ma trận nhầm lẫn:

Đây là bảng cơ bản giúp so sánh giữa kết quả **thực tế** và **dự đoán của mô hình**:

	DỰ ĐOÁN CÓ BỆNH	**DỰ ĐOÁN KHÔNG BỆNH**
THỰC TẾ CÓ BỆNH	TP	FN
THỰC TẾ KHÔNG BỆNH	FP	TN

Bảng 2.2 Ma trận so sánh

Ý nghĩa trong y tế:

TP (đúng bệnh): Bệnh nhân có bệnh và mô hình dự đoán đúng

TN (đúng không bệnh): Bệnh nhân không bệnh và mô hình dự đoán đúng

FP (báo nhầm): Không bệnh nhưng mô hình báo có bệnh → gây lo lắng, tốn thêm xét nghiệm

FN (bỏ sót): Có bệnh nhưng mô hình báo không → **nguy hiểm nhất**

Accuracy (Độ chính xác):

$$Accuracy=\frac{TP+TN}{TP+TN+FP+FN}$$

Cho biết tổng thể mô hình dự đoán đúng bao nhiêu phần trăm

Tuy nhiên, chỉ số này có thể gây hiểu nhầm nếu dữ liệu không cân bằng

Ví dụ: nếu 90% bệnh nhân không bệnh, mô hình luôn đoán "không bệnh" vẫn đạt 90% accuracy → nhưng thực tế không có giá trị

Precision (Độ chính xác khi dự đoán có bệnh):

$$Precision = \frac{TP}{TP+FP}$$

Trong số các ca được dự đoán "có bệnh", bao nhiêu ca là đúng

Precision cao → ít báo nhầm

Quan trọng khi việc điều trị có thể gây tác dụng phụ

Recall (Độ nhạy):

$$Recall = \frac{TP}{TP+FN}$$

Trong số những người thật sự có bệnh, mô hình phát hiện được bao nhiêu

Recall cao → ít bỏ sót bệnh

Đây là chỉ số **rất quan trọng trong y tế**, vì bỏ sót bệnh có thể nguy hiểm

F1-Score:

$$F1 = \frac{2 \cdot (Precision \cdot Recall)}{Precision + Recall}$$

Là sự kết hợp giữa Precision và Recall

Dùng khi cần cân bằng giữa "không báo nhầm" và "không bỏ sót"

Đây là chỉ số chính để so sánh mô hình trong đề tài

ROC-AUC:

ROC là đường cong thể hiện sự đánh đổi giữa:

Phát hiện đúng bệnh (Recall)

Báo nhầm (False Positive)

AUC là diện tích dưới đường cong:

Gần 1 → mô hình rất tốt

Gần 0.5 → gần như đoán ngẫu nhiên

Đánh giá thường dùng:

0.90 → rất tốt

0.80 – 0.90 → tốt

0.70 – 0.80 → chấp nhận được

< 0.70 → kém

Ưu điểm: không phụ thuộc vào ngưỡng quyết định → phù hợp để so sánh mô hình

2.4.2. Hiệu chỉnh xác suất (Calibration)

Một điểm rất quan trọng trong y tế là:
xác suất mô hình đưa ra có đúng với thực tế không

Ví dụ:

Mô hình dự đoán 100 người có **70% nguy cơ**

Nếu khoảng 70 người thật sự mắc bệnh → mô hình được xem là **đáng tin cậy**

Tuy nhiên:

Các mô hình như Random Forest hay XGBoost thường đưa ra xác suất quá "cực đoan" (gần 0 hoặc 1)

Vì vậy, hệ thống sử dụng phương pháp hiệu chỉnh để:

Làm cho xác suất sát với thực tế hơn

Giúp bác sĩ có thể tin vào con số (ví dụ: 72% là có ý nghĩa thật)

2.5. Nguồn Dữ Liệu Huấn Luyện — Kaggle và Hugging Face

Hệ thống **CardioPredict AI** sử dụng bộ dữ liệu **Heart Disease UCI (University of California, Irvine)** — một trong những bộ dữ liệu tiêu chuẩn và được sử dụng rộng rãi nhất trong lĩnh vực nghiên cứu dự đoán bệnh tim bằng Machine Learning. Bộ dữ liệu này đã xuất hiện trong rất nhiều công trình khoa học và được xem là "benchmark" (mốc chuẩn) để đánh giá hiệu năng của các mô hình.

Về nguồn truy cập, bộ dữ liệu có thể được lấy từ hai nền tảng chính, đáp ứng các nhu cầu sử dụng khác nhau:

Kaggle: Đây là nguồn phổ biến và dễ tiếp cận nhất đối với sinh viên và nhà phát triển. Trên Kaggle, bộ dữ liệu đã được xử lý sẵn với các tên file như *heart_disease_processed.csv* hoặc *heart.csv*. Các phiên bản này thường đã được làm sạch, loại bỏ dữ liệu lỗi và chuẩn hóa định dạng, giúp

người dùng có thể tải về và sử dụng ngay mà không cần thực hiện nhiều bước tiền xử lý phức tạp. Điều này đặc biệt phù hợp trong giai đoạn phát triển nhanh mô hình hoặc thử nghiệm.

Hugging Face Hub: Đây là nền tảng hiện đại hơn, phù hợp với các hệ thống Machine Learning chuyên nghiệp. Bộ dữ liệu trên Hugging Face đã được chuẩn hóa theo định dạng của thư viện **datasets**, cho phép truy cập trực tiếp thông qua API. Nhờ đó, dữ liệu có thể được tích hợp thẳng vào pipeline huấn luyện, hỗ trợ tự động hóa và triển khai mô hình một cách linh hoạt hơn, đặc biệt trong môi trường production hoặc khi cần mở rộng hệ thống.

Nhìn chung,việc bộ dữ liệu được cung cấp trên nhiều nền tảng khác nhau mang lại sự linh hoạt cao trong quá trình phát triển hệ thống. Người dùng có thể lựa chọn Kaggle để triển khai nhanh và đơn giản, hoặc sử dụng Hugging Face khi cần xây dựng pipeline Machine Learning bài bản, có khả năng mở rộng và tích hợp sâu với các công cụ AI hiện đại.

Heart Disease UCI không chỉ là bộ dữ liệu đáng tin cậy về mặt học thuật mà còn rất thuận tiện trong thực tế triển khai, giúp rút ngắn thời gian phát triển và đảm bảo chất lượng cho hệ thống CardioPredict AI.

2.6. Quy Trình Xây Dựng Mô Hình AI — Từ Dữ Liệu Đến Triển Khai

Phần này mô tả toàn bộ quy trình xây dựng hệ thống AI trong đề tài, từ dữ liệu ban đầu đến khi triển khai thành một hệ thống có thể sử dụng thực tế. Quy trình được thiết kế theo hướng end-to-end, đảm bảo tính nhất quán, dễ tái sử dụng và phù hợp triển khai trong môi trường thực tế.

2.6.1. Tổng quan Pipeline

Hệ thống được triển khai trong file train_model.py, bao gồm 9 bước chính theo thứ tự sau:

1. Tải dữ liệu từ file CSV và kiểm tra cấu trúc các cột
2. Làm sạch dữ liệu: xử lý giá trị thiếu và giá trị bất thường
3. Chia dữ liệu thành tập huấn luyện và kiểm tra (train/test)
4. Huấn luyện và so sánh nhiều mô hình Machine Learning
5. Hiệu chỉnh xác suất dự đoán để tăng độ tin cậy
6. Đánh giá mô hình bằng các chỉ số quan trọng
7. Lưu mô hình và các thành phần liên quan (model, scaler, metadata)
8. Kiểm tra thử nghiệm trên một số trường hợp mẫu
9. Tích hợp vào hệ thống web thông qua Flask API

Pipeline này giúp đảm bảo toàn bộ quá trình từ dữ liệu đến triển khai được tự động hóa và nhất quán.

2.6.2. Làm sạch dữ liệu

Chuyển kiểu dữ liệu:
Tất cả các cột được chuyển về dạng số (numeric). Nếu có giá trị không hợp lệ, hệ thống sẽ gán thành giá trị thiếu (NaN).

Xử lý giá trị thiếu:

Các đặc trưng đầu vào được điền bằng **giá trị trung vị (median)**

Nhãn (target) được điền mặc định là 0 nếu bị thiếu

Xử lý giá trị ngoại lai (outlier):
Áp dụng phương pháp IQR để giới hạn giá trị trong khoảng hợp lý, tránh ảnh hưởng tiêu cực đến mô hình.

Chuẩn hóa biến phân loại:
Các biến dạng phân loại được làm tròn và giới hạn trong khoảng giá trị hợp lệ (ví dụ: cp từ 0 đến 3).

Kết quả: Dữ liệu sạch, đầy đủ và sẵn sàng cho huấn luyện.

2.6.3. Phân chia dữ liệu và chuẩn hóa

Chia dữ liệu:

80% dùng để huấn luyện

20% dùng để kiểm tra

Sử dụng stratify=y để giữ nguyên tỷ lệ có/không bệnh trong cả hai tập

Chuẩn hóa dữ liệu (StandardScaler):

Chỉ áp dụng cho các đặc trưng liên tục

Tính toán (fit) trên tập train

Áp dụng (transform) cho tập test

Điều này giúp tránh lỗi data leakage (rò rỉ thông tin từ test sang train).

2.6.4. So sánh các mô hình Machine Learning

Hệ thống sử dụng và so sánh 3 mô hình phổ biến:

Mô hình	Cấu hình chính	Đặc điểm
Logistic Regression	C=1.0, max_iter=4000	Dễ hiểu, dễ giải thích
Random Forest	350 cây, depth=10	Xử lý tốt dữ liệu phi tuyến
XGBoost	300 cây, learning_rate=0.05	Hiệu suất cao nhất

Bảng 2.3 So sánh các mô hình Machine Learning

Sử dụng cross-validation 5-fold để đánh giá chính xác hơn

Áp dụng Pipeline (Scaler → Model) để tránh sai lệch

Mô hình có kết quả tốt nhất sẽ được chọn cho bước tiếp theo.

2.6.5. Hiệu chỉnh xác suất dự đoán

Một vấn đề phổ biến của các mô hình ML là dự đoán xác suất quá tự tin (overconfident).

Để khắc phục, hệ thống sử dụng:

CalibratedClassifierCV (Platt Scaling)

Cross-validation 5-fold

Sau khi hiệu chỉnh:

Xác suất được điều chỉnh về gần với thực tế hơn

Giới hạn trong khoảng 1% đến 95% để tránh cực đoan

Điều này rất quan trọng trong y tế, vì bác sĩ cần xác suất đáng tin cậy để ra quyết định.

2.6.6. Đánh giá mô hình

Mô hình được đánh giá bằng các chỉ số quan trọng:

Chỉ số	Ý nghĩa
Accuracy	Tỷ lệ dự đoán đúng tổng thể
Precision	Trong số dự đoán có bệnh, bao nhiêu là đúng
Recall	Phát hiện được bao nhiêu ca bệnh thật
F1-score	Cân bằng giữa Precision và Recall

Bảng 2.4 Đánh giá mô hình

Trong lĩnh vực y tế, Recall thường được ưu tiên cao để tránh bỏ sót bệnh nhân.

Kết quả:

Mô hình đạt độ chính xác khoảng 94.2% sau khi hiệu chỉnh

2.6.7. Đóng gói mô hình

Sau khi huấn luyện, mô hình được lưu lại dưới dạng một "gói" bao gồm:

Mô hình đã huấn luyện

Bộ chuẩn hóa dữ liệu (scaler)

Danh sách các đặc trưng

Thông tin phiên bản và độ chính xác

Việc đóng gói giúp dễ dàng tái sử dụng và triển khai trong hệ thống thực tế.

2.6.8. Suy diễn thời gian thực (Inference)

Khi người dùng nhập dữ liệu, hệ thống sẽ:

1. Kiểm tra tính hợp lệ của 13 đặc trưng đầu vào
2. Chuẩn hóa dữ liệu giống như khi huấn luyện
3. Dự đoán xác suất mắc bệnh bằng predict_proba()
4. Chuyển đổi thành risk_score (%)

Ngoài ra, hệ thống còn cung cấp thêm:

Khoảng tin cậy 95%: ước lượng độ ổn định của dự đoán

Độ bất định (uncertainty): đo mức độ chắc chắn của mô hình

Phân tích yếu tố nguy cơ: giải thích các đặc trưng ảnh hưởng đến kết quả

Suy diễn ECG cơ bản: hỗ trợ thêm thông tin lâm sàng

Điều này giúp kết quả không chỉ là "có/không" mà còn có tính giải thích.

2.6.9. Phân tầng nguy cơ

Dựa trên xác suất dự đoán, hệ thống chia thành 4 mức nguy cơ:

Mức độ	Xác suất	Hành động khuyến nghị
Thấp	< 30%	Tái khám định kỳ
Trung bình	30–49%	Gặp bác sĩ trong 1 tháng
Cao	50–69%	Khám chuyên khoa sớm
Rất cao	≥ 70%	Chuyển khám tim mạch ngay

Bảng 2.5 Phân tầng nguy cơ

Cách phân tầng này giúp hỗ trợ bác sĩ ra quyết định nhanh và hợp lí

2.7. Cơ Sở Dữ Liệu

2.7.1. Khái Niệm Cơ Sở Dữ Liệu Quan Hệ

Cơ sở dữ liệu quan hệ (Relational Database) tổ chức dữ liệu dưới dạng các bảng (Table) có liên kết với nhau thông qua khóa chính (Primary Key) và khóa ngoại (Foreign Key). Đây là loại CSDL phổ biến nhất trong phát triển ứng dụng web, đảm bảo tính toàn vẹn dữ liệu và hỗ trợ truy vấn phức tạp hiệu quả.

Đặc điểm quan trọng:

-ACID Properties: Atomicity (nguyên tử), Consistency (nhất quán), Isolation (độc lập), Durability (bền vững) đảm bảo an toàn dữ liệu tài chính.

- Transactions: Đảm bảo các thao tác tài chính (thêm/sửa/xóa giao dịch) được thực hiện toàn vẹn hoặc không thực hiện gì cả.

- Referential Integrity: Ràng buộc FK đảm bảo dữ liệu luôn nhất quán (ví dụ: không thể xóa danh mục đang được sử dụng bởi giao dịch).

2.7.2. Microsoft SQL Server

Microsoft SQL Server là RDBMS (Relational Database Management System) phổ biến của Microsoft, hỗ trợ ngôn ngữ T-SQL (Transact-SQL) mở rộng SQL chuẩn với nhiều tính năng lập trình bổ sung.

Lý do lựa chọn SQL Server cho SpendSmart AI:

Bảo mật dữ liệu tài chính: Hỗ trợ mã hóa dữ liệu (Transparent Data Encryption), row-level security và kiểm toán toàn diện.

Hiệu suất truy vấn: Query Optimizer tự động tối ưu kế hoạch thực thi, chỉ mục thông minh cho truy vấn thống kê tài chính phức tạp.

Stored Procedures: Đóng gói các logic tính toán tài chính (tổng thu, tổng chi, số dư, so sánh ngân sách) phía CSDL.

Window Functions: Hỗ trợ các hàm phân tích như SUM() OVER(), LAG(), LEAD() rất hữu ích cho phân tích chuỗi thời gian tài chính.

Unicode: Hỗ trợ NVARCHAR, lưu trữ tiếng Việt chuẩn với collation Vietnamese_CI_AS.

2.7.3. SQL (Structured Query Language)

SQL là ngôn ngữ chuẩn để tương tác với CSDL quan hệ. Trong SpendSmart AI, SQL được dùng để:

Truy vấn dữ liệu giao dịch theo nhiều chiều thời gian cho báo cáo.

Tính toán tổng thu, tổng chi, số dư theo từng danh mục và khoảng thời gian.

So sánh chi tiêu thực tế với ngân sách đã đặt.

Tạo stored procedures tính toán KPI tài chính phức tạp.

CHƯƠNG 3: Phân Tích & Thiết Kế Hệ Thống

3.1. Mô tả bộ dữ liệu UCI Heart Disease (Dataset):

3.1.1. Nguồn gốc và lịch sử

Bộ dữ liệu được sử dụng trong đề tài là **UCI Heart Disease Dataset (Cleveland Database)**, thu thập tại Phòng khám Cleveland (Cleveland Clinic Foundation, Ohio, Hoa Kỳ) bởi Robert Detrano và cộng sự vào cuối thập niên 1980. Đây là một trong những bộ dữ liệu y tế được sử dụng nhiều nhất trong cộng đồng nghiên cứu Machine Learning với hơn 800 bài báo khoa học tham chiếu.

Bộ dữ liệu gốc có 76 thuộc tính được đo lường trên mỗi bệnh nhân, nhưng bộ con 13 thuộc tính lâm sàng quan trọng nhất đã trở thành tiêu chuẩn trong nghiên cứu học thuật. Dữ liệu gồm 303 mẫu, trong đó 165 mẫu thuộc lớp dương (có bệnh tim, target=1) và 138 mẫu thuộc lớp âm (không có bệnh tim, target=0), tỷ lệ xấp xỉ 54%–46% — một tỷ lệ khá cân bằng, thuận lợi cho training.

File dữ liệu trong hệ thống được lưu tại

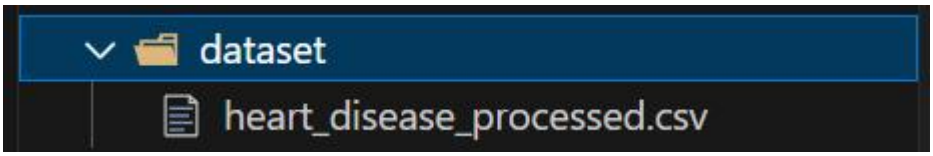

3.1.2. Ý nghĩa y khoa của từng thuộc tính

1. Age (Tuổi) — Biến liên tục: Tuổi là yếu tố nguy cơ không thể thay đổi của bệnh tim mạch. Nguy cơ bắt đầu tăng đáng kể ở nam giới từ 45 tuổi và nữ giới từ 55 tuổi trở lên. Trong dataset này, tuổi dao động từ 29 đến 77, với trung bình 54.4 tuổi và độ lệch chuẩn 9.0 năm.

2. Sex (Giới tính) — Biến nhị phân (0: Nữ, 1: Nam): Nam giới có nguy cơ mắc bệnh động mạch vành cao hơn nữ giới trước tuổi mãn kinh, do ảnh hưởng bảo vệ của estrogen đối với thành mạch máu. Trong dataset, 68% là nam giới — phản ánh xu hướng tỷ lệ mắc bệnh cao hơn ở nam.

3. CP (Loại đau ngực) — Biến phân loại (0-3): Đây là một trong những đặc trưng quan trọng nhất. Irony trong dataset: nhóm "không có triệu chứng" (cp=0, asymptomatic) có tỷ lệ bệnh tim cao nhất — điều này phản ánh thực tế rằng nhiều bệnh nhân bệnh tim nặng không có triệu chứng đau ngực điển hình (silent ischemia), trong khi đau ngực điển hình (cp=1) đôi khi có thể do nguyên nhân khác. Phân loại: 0=Asymptomatic, 1=Typical angina (đau thắt ngực điển hình), 2=Atypical angina, 3=Non-anginal pain.

4. Trestbps (Huyết áp nghỉ) — Biến liên tục (mmHg): Huyết áp tâm thu được đo lúc nhập viện. Tăng huyết áp mạn tính (≥140 mmHg) làm tổn

thương nội mô mạch máu, dẫn đến xơ vữa động mạch. Trong dataset, dao động 94–200 mmHg, trung bình 131.6 mmHg.

5. Chol (Cholesterol) — Biến liên tục (mg/dL): Nồng độ cholesterol toàn phần trong huyết thanh. Theo khuyến cáo của Hiệp hội Tim mạch Hoa Kỳ (AHA): <200 mg/dL là mức mong muốn, 200-239 mg/dL là "giáp ranh cao", ≥240 mg/dL là cao. Trong dataset, dao động 126-564 mg/dL — có một số giá trị bất thường cao (outlier) có thể do sai số đo lường hoặc trường hợp tăng cholesterol gia đình.

6. FBS (Đường huyết lúc đói > 120 mg/dL) — Biến nhị phân: 1 nếu đường huyết lúc đói > 120 mg/dL, 0 ngược lại. Đây là chỉ báo nguy cơ đái tháo đường — yếu tố nguy cơ tim mạch độc lập mạnh. Trong dataset, khoảng 15% bệnh nhân có FBS cao.

7. Restecg (Kết quả ECG nghỉ) — Biến phân loại (0-2): 0=Bình thường, 1=Bất thường sóng ST-T (có thể do thiếu máu cơ tim), 2=Phì đại thất trái (hypertrophy). Kết quả ECG bất thường là dấu hiệu tổn thương tim có sẵn, tăng nguy cơ đáng kể.

8. Thalach (Nhịp tim tối đa khi gắng sức) — Biến liên tục (bpm): Nhịp tim tối đa đạt được trong nghiệm pháp gắng sức. Nhịp tim tối đa lý thuyết = 220 - tuổi. Bệnh nhân có bệnh tim thường không đạt được nhịp tim tối đa dự kiến vì cơ tim bị thiếu máu và phải giảm gắng sức sớm. Đây thường là một trong những đặc trưng phân biệt tốt nhất giữa hai lớp.

9. Exang (Đau thắt ngực khi gắng sức) — Biến nhị phân: 1 nếu xuất hiện đau ngực khi làm nghiệm pháp gắng sức. Đây là bằng chứng trực tiếp của thiếu máu cơ tim gắng sức — nguyên nhân gần như chắc chắn do bệnh động mạch vành.

10. Oldpeak (ST Depression) — Biến liên tục: Mức độ chênh xuống của đoạn ST trên ECG sau gắng sức so với nghỉ, tính theo mm. Chênh ST ≥1mm thường được coi là bằng chứng của thiếu máu cơ tim gắng sức. Trong dataset, dao động 0.0–6.2 mm.

11. Slope (Độ dốc đoạn ST) — Biến phân loại (0-2): 0=Dốc lên (upsloping — tiên lượng tốt hơn), 1=Bằng phẳng (flat — đáng ngại), 2=Dốc xuống (downsloping — nguy cơ cao nhất). Độ dốc ST phản ánh đáp ứng huyết động của tim khi gắng sức.

12. CA (Số mạch máu chính bị tổn thương qua chụp huỳnh quang) — Biến thứ tự (0-3): Số lượng động mạch coronary chính bị tắc nghẽn đáng kể (>50% lòng mạch) được phát hiện qua chụp mạch huỳnh quang (fluoroscopy). CA=0: không có, CA=3: cả 3 nhánh chính bị tổn thương (three-vessel disease — tiên lượng xấu nhất). Đây thường là đặc trưng quan trọng nhất sau phân tích.

13. Thal (Thalassemia / Xạ hình tưới máu cơ tim) — Biến phân loại (1-3): Kết quả xạ hình tâm thất đánh giá tưới máu cơ tim: 1=Khiếm khuyết cố định (fixed defect — sẹo sau nhồi máu cũ), 2=Bình thường, 3=Khiếm khuyết hồi phục (reversible defect — thiếu máu gắng sức, không hoại tử). Giá trị 1 và 3 đều liên quan đến nguy cơ cao.

3.2. Tiền xử lý dữ liệu (Data Preprocessing):

3.2.1. Xử lý giá trị thiếu (Missing Values)

Trong bộ dữ liệu Cleveland, một số cột như **ca** và **thal** có chứa giá trị bị thiếu. Để xử lý vấn đề này, hệ thống sử dụng phương pháp **điền giá trị trung vị (median)** của từng cột vào các vị trí bị thiếu.

Cách làm này được lựa chọn thay vì dùng giá trị trung bình (mean), vì trung vị ít bị ảnh hưởng bởi các giá trị quá lớn hoặc quá nhỏ (outlier). Điều này đặc biệt quan trọng với các chỉ số như cholesterol hoặc huyết áp, vốn có thể xuất hiện các giá trị bất thường.

Kết quả: Dữ liệu được đầy đủ mà không làm sai lệch phân bố ban đầu.

3.2.2. Xử lý giá trị ngoại lai (Outlier)

Trong dữ liệu y tế, các giá trị quá cao hoặc quá thấp có thể là:

Trường hợp bệnh lý đặc biệt (hợp lệ).

Hoặc lỗi trong quá trình đo đạc.

Thay vì xóa các giá trị này, hệ thống sử dụng phương pháp **giới hạn giá trị** theo khoảng hợp lý. Cụ thể, mỗi giá trị sẽ được đưa về trong khoảng an toàn dựa trên phân bố của dữ liệu.

Phương pháp này giữ lại các điểm dữ liệu thay vì xóa chúng (không mất mẫu), nhưng giới hạn ảnh hưởng cực đoan của các giá trị ngoại lai.

Giữ lại toàn bộ dữ liệu (không bị mất mẫu).

Hạn chế ảnh hưởng tiêu cực của các giá trị quá cực đoan.

3.2.3. Xử lý biến phân loại

Các biến phân loại như:

Giới tính (sex)

Loại đau ngực (cp)

Đường huyết (fbs)

Điện tâm đồ (restecg)

Đau khi gắng sức (exang)

Độ dốc ST (slope)

Số mạch máu tổn thương (ca)

Kết quả thal (thal)

Các biến phân loại (sex, cp, fbs, restecg, exang, slope, ca, thal) đã được mã hóa dưới dạng số nguyên trong bộ dữ liệu gốc, do đó không cần one-hot encoding thêm. Tuy nhiên, cần kiểm tra và đảm bảo các giá trị này nằm trong khoảng hợp lệ.

3.2.4. Chuẩn hóa dữ liệu (Feature Scaling)

Một số đặc trưng dạng số liên tục như:

Tuổi (age)

Huyết áp (trestbps)

Cholesterol (chol)

Nhịp tim tối đa (thalach)

Oldpeak

Được thực hiện **chuẩn hóa (standardization)**.

Cách chuẩn hóa:

Đưa dữ liệu về dạng có giá trị trung bình = 0

Độ lệch chuẩn = 1

Mục đích:

Giúp các thuật toán như Logistic Regression học tốt hơn

Tránh việc các biến có giá trị lớn "lấn át" các biến khác

Lưu ý quan trọng:

StandardScaler được **fit trên tập training** và chỉ **transform trên tập test** — nguyên tắc quan trọng để tránh data leakage (rò rỉ thông tin từ test sang train). Đây là lỗi phổ biến trong nhiều nghiên cứu học sinh viên.

Sau khi scaling, các đặc trưng liên tục có mean=0 và std=1. Điều này quan trọng cho Logistic Regression (do gradient descent nhạy cảm với scale) và cũng có lợi cho KNN, SVM nếu sử dụng sau này. Random Forest và XGBoost về lý thuyết không cần scaling, nhưng cũng không bị ảnh hưởng tiêu cực.

3.3. Yêu cầu hệ thống

3.3.1 Yêu Cầu Chức Năng

Quản Lý Người Dùng

Chức năng	Mô tả
Đăng ký tài khoản	Nhập họ tên, email, mật khẩu; kiểm tra email trùng; lưu mật khẩu mã hóa PBKDF2
Đăng nhập email/mật khẩu	Xác thực, cấp JWT token
Đăng nhập Google OAuth	Tích hợp Google OAuth 2.0, tạo tài khoản tự động
Quên mật khẩu (OTP)	Gửi OTP 6 chữ số qua email SMTP, đặt lại mật khẩu
Đăng xuất	Hủy phiên phía client
Phân quyền RBAC	3 vai trò: admin, doctor, nurse

Bảng 3.1 Phân tầng nguy cơ

Dự Đoán Nguy Cơ Tim Mạch

Chức năng	Mô tả
Nhập thông số lâm sàng	Form 13 chỉ số UCI
Dự đoán AI	Gọi /api/predict, nhận xác suất từ mô hình ML
Hiển thị kết quả	Mức nguy cơ, % xác suất, khoảng tin cậy 95%, độ bất định
Phân tích yếu tố nguy cơ	Liệt kê yếu tố tăng/giảm nguy cơ theo trọng số
Khuyến nghị lâm sàng	Hành động y tế cụ thể theo mức nguy cơ
Chỉ số ECG	Ước lượng HR, PR, QRS, QT, QTc
Xuất PDF	Tạo báo cáo PDF lưu hồ sơ bệnh nhân

Bảng 3.2 Dự Đoán Nguy Cơ Tim Mạch

Quản Lý Lịch Sử Chẩn Đoán

Chức năng	Mô tả
Danh sách chẩn đoán	Phân trang, lọc theo mức nguy cơ, tìm theo tên
Chi tiết ca chẩn đoán	Xem đầy đủ thông số và kết quả AI
Thống kê tổng hợp	Tổng ca, phân bố nguy cơ, biểu đồ 30 ngày

Bảng 3.3 Quản Lý Lịch Sử Chẩn Đoán

Giám Sát Hệ Thống

Chức năng	Mô tả
Dashboard vận hành	Uptime, latency p95, error rate, request/phút
Audit Log	Nhật ký hành động: predict, auth, admin
Báo cáo Drift	Phát hiện thay đổi phân bố dữ liệu (z-score)
Báo cáo Fairness	Phân tích công bằng AI theo giới tính và tuổi
Model Card	Metadata mô hình: phiên bản, accuracy, ngày train

Bảng 3.4 Giám Sát Hệ Thống

Quản Trị (Admin)

Chức năng	Mô tả
Danh sách user	Admin xem tất cả tài khoản
Cập nhật vai trò	Admin thay đổi role (admin/doctor/nurse)

Bảng 3.5 Quản Trị (Admin)

3.3.2 Yêu Cầu Phi Chức Năng

Hiệu Năng

Tiêu chí	Chỉ tiêu
Thời gian phản hồi API predict	< 2 giây (kể cả perturbation sampling 40 lần)
Tải trang đầu (React)	< 3 giây (FCP)
Throughput	≥ 20 req/giây (Waitress WSGI)
Model bundle	~325 KB, load < 500ms

Bảng 3.6 Bảng Hiệu Năng

Bảo Mật

Yêu cầu	Triển khai
Xác thực	JWT HMAC-SHA256 tự quản lý
Mã hóa mật khẩu	Werkzeug PBKDF2/Scrypt — không lưu plain text
Nâng cấp hash tự động	Phát hiện plain text cũ → hash + UPDATE DB
CORS	Chỉ cho phép /api/* với header Content-Type, Authorization
SQL Injection	Parameterized queries (? placeholder) toàn bộ
Input Validation	Kiểm tra đủ trường, phạm vi giá trị trước predict

Bảng 3.7 Bảo Mật

Độ Tin Cậy & Dự Phòng

Yêu cầu	Triển khai
Fallback không có model	Chuyển sang rule-based prediction 10 quy tắc lâm sàng
Fallback CSDL	SQLite khi SQL Server không khả dụng
Giới hạn xác suất	Clip trong [0.01, 0.95]
Error handling	try/except mọi endpoint, thông báo lỗi rõ ràn

Bảng 3.8 Độ Tin Cậy & Dự Phòng

3.4. Thiết kế cơ sở dữ liệu

Bảng Bệnh Nhân:

Tên cột	Kiểu dữ liệu	Ghi chú
Id	INT (PK, Identity)	Khóa chính, tự tăng
Ten	NVARCHAR(50)	Họ tên bệnh nhân
Tuoi	INT	Tuổi bệnh nhân
GioiTinh	NVARCHAR(10)	Giới tính (Nam/Nữ)
LoaiDauNguc	INT	Loại đau ngực (0–3)
HuyetApNghi	INT	Huyết áp lúc nghỉ (mmHg)
Cholesterol	INT	Cholesterol máu
DuongHuyetLucDoi	BIT	Đường huyết >120 mg/dL
KetQuaECG	INT	Kết quả điện tâm đồ
NhipTimToiDa	INT	Nhịp tim tối đa
DauThatNgucKhiTap	BIT	Đau ngực khi vận động
ST_Depression	FLOAT	Mức chênh ST
DoDocST	INT	Độ dốc ST
SoMachMauChinh	INT	Số mạch máu bị tổn thương
Thalassemia	INT	Kết quả xét nghiệm Thal
KetQuaDuDoan	NVARCHAR(50)	Kết quả AI dự đoán
NgayChanDoan	DATETIME	Ngày chẩn đoán
UserId	INT (FK)	Liên kết tài khoản
RiskScore	FLOAT	Điểm nguy cơ
Prediction	BIT	0: không bệnh, 1: có bệnh

Bảng 3.9 Thiết kế cơ sở dữ liệu

Bảng Điểm Nguy Cơ:

Tên cột	Kiểu dữ liệu	Ghi chú
Id	INT (PK, Identity)	Khóa chính
BenhNhanId	INT (FK)	Liên kết bảng BenhNhan
DiemNguyCo	FLOAT	Điểm nguy cơ AI
MucNguyCo	NVARCHAR(50)	Thấp / Trung bình / Cao
NgayTao	DATETIME	Thời điểm tạo

Bảng 3.10 Bảng Điểm Nguy Cơ

Bảng Tài Khoản

Tên cột	Kiểu dữ liệu	Ghi chú
Id	INT (PK, Identity)	Khóa chính
TenDangNhap	NVARCHAR(50)	Tên đăng nhập
MatKhau	NVARCHAR(255)	Mật khẩu đã mã hóa
VaiTro	NVARCHAR(20)	Admin / BacSi
NgayTao	DATETIME	Ngày tạo tài khoản

Bảng 3.11 Bảng Tài Khoản

Bảng Báo Cáo

Tên cột	Kiểu dữ liệu	Ghi chú
Id	INT (PK, Identity)	Khóa chính
TaiKhoanId	INT (FK)	Người tạo báo cáo
BenhNhanId	INT (FK)	Liên kết bệnh nhân
LoaiBaoCao	NVARCHAR(50)	Loại báo cáo
NgayTao	DATETIME	Thời điểm tạo
DuongDanFile	NVARCHAR(255)	Đường dẫn file
MoTa	NVARCHAR(255)	Mô tả

Bảng 3.12 Bảng Báo Cáo

3.5. Thiết Kế API

Kiến trúc

Hệ thống được xây dựng theo mô hình **API web**, sử dụng **Flask** để tạo các dịch vụ RESTful cho phép frontend và các hệ thống khác giao tiếp với backend.

Trong môi trường triển khai thực tế, hệ thống sử dụng **Waitress (WSGI server)** để chạy ứng dụng Flask, giúp đảm bảo hiệu năng ổn định và phù hợp cho production.

Địa chỉ truy cập (Base URL):
http://<server>:5001

Định dạng dữ liệu trao đổi:
Tất cả dữ liệu gửi và nhận đều ở dạng **JSON**, giúp dễ tích hợp và xử lý.

Xác thực người dùng (Authentication):
Hệ thống sử dụng **JWT (JSON Web Token)** để xác thực.
Token được ký bằng thuật toán **HMAC-SHA256** và được tự xây dựng trong hệ thống.

Bảng Endpoints

Health & Info

Method	Endpoint	Mô tả	Auth
GET	/api/health	Trạng thái server, DB, model	Không
GET	/api/model-info	Metadata mô hình AI	Không
GET	/api/feature-importance	Tầm quan trọng 13 đặc trưng	Không

Bảng 3.13 Bảng Endpoints

Authentication

Method	Endpoint	Mô tả	Auth
POST	/api/auth/register	Đăng ký tài khoản	Không
POST	/api/auth/login	Đăng nhập → JWT token	Không
POST	/api/auth/google-login	Google OAuth 2.0	Không
POST	/api/auth/forgot-password	Gửi OTP email	Không
POST	/api/auth/verify-otp	Xác thực OTP + đặt lại mật khẩu	Không
GET	/api/auth/me	Thông tin user hiện tại	JWT

Bảng 3.14 Bảng Authentication

Dự Đoán

Method	Endpoint	Mô tả	Auth
POST	/api/predict	Dự đoán nguy cơ từ 13 thông số	JWT

Bảng 3.15 Bảng Dự Đoán

Chẩn Đoán

Method	Endpoint	Mô tả	Auth
GET	/api/diagnoses	Danh sách (phân trang, lọc, tìm)	JWT
GET	/api/diagnoses/<id>	Chi tiết một bản ghi	JWT
GET	/api/diagnoses/stats	Thống kê tổng hợp	JWT
GET	/api/diagnoses/my	Lịch sử của bác sĩ đang đăng nhập	JWT

Bảng 3.16 Chẩn Đoán

Giám Sát Hệ Thống

Method	Endpoint	Mô tả	Auth
GET	/api/system/stats	Uptime, latency, error rate	JWT
GET	/api/system/audit-log	Nhật ký hành động	JWT
GET	/api/system/drift-report	Drift phân phối dữ liệu	JWT
GET	/api/system/fairness-report	Công bằng AI theo giới tính/tuổi	JWT

Bảng 3.17 Giám Sát Hệ Thống

3.6. Luồng Nghiệp Vụ Chính

3.6.1 Luồng đăng nhập

Khi người dùng thực hiện đăng nhập, hệ thống xử lý theo các bước sau:

Đầu tiên, người dùng nhập email và mật khẩu trên giao diện. Thông tin này được gửi từ client đến server thông qua API POST /api/auth/login.

Tại phía backend (Flask API), hệ thống sẽ truy vấn cơ sở dữ liệu SQL Server để tìm tài khoản tương ứng với email đã nhập. Nếu tồn tại, hệ thống lấy thông tin mật khẩu đã lưu trong database để tiến hành kiểm tra.

Mật khẩu người dùng nhập sẽ được so sánh với mật khẩu đã mã hóa bằng hàm check_password_hash(). Trong trường hợp hệ thống phát hiện mật khẩu cũ chưa được mã hóa, nó sẽ tự động cập nhật sang dạng hash để đảm bảo an toàn.

Nếu thông tin đăng nhập hợp lệ, hệ thống sẽ tạo một **JWT token** và gửi lại cho client kèm theo thông tin người dùng. Token này sẽ được lưu trên trình duyệt (thường là localStorage) và sử dụng cho các request tiếp theo.

3.6.2 Luồng dự đoán nguy cơ bệnh tim (luồng chính)

Đây là luồng quan trọng nhất của hệ thống.

Trước tiên, bác sĩ hoặc người dùng nhập đầy đủ 13 thông số lâm sàng trên giao diện. Frontend sẽ kiểm tra tính hợp lệ của dữ liệu trước khi gửi đi (ví dụ: không để trống, đúng kiểu dữ liệu).

Sau đó, dữ liệu được gửi đến API POST /api/predict kèm theo **JWT token** để xác thực người dùng. Nếu token không hợp lệ hoặc hết hạn, hệ thống sẽ trả về lỗi 401.

Khi request hợp lệ, backend tiếp tục kiểm tra lại 13 trường dữ liệu bắt buộc. Nếu thiếu hoặc sai định dạng, hệ thống trả về lỗi 400.

Tiếp theo, dữ liệu được đưa qua bước chuẩn hóa bằng **StandardScaler**, đảm bảo dữ liệu đầu vào phù hợp với mô hình đã huấn luyện.

Sau khi chuẩn hóa, hệ thống sử dụng mô hình AI (XGBoost) để tính toán xác suất mắc bệnh thông qua hàm predict_proba(). Kết quả là một giá trị **risk_score (điểm nguy cơ)**.

Ngoài ra, hệ thống còn thực hiện các phân tích bổ sung để tăng độ tin cậy và khả năng giải thích:

Tính **khoảng tin cậy 95%** bằng phương pháp tạo nhiễu dữ liệu (perturbation) 40 lần, sau đó lấy các giá trị phần trăm 2.5 và 97.5.

Phân tích các yếu tố ảnh hưởng đến kết quả dự đoán (tăng nguy cơ hoặc bảo vệ) thông qua phương pháp tương tự SHAP.

Tính toán thêm các chỉ số ECG như nhịp tim (HR), PR, QRS, QTc.

Đưa ra khuyến nghị lâm sàng dựa trên mức độ nguy cơ.

Sau khi hoàn tất, hệ thống sẽ lưu thông tin bệnh nhân vào bảng BenhNhan và ghi lại hoạt động vào bảng AuditLog để phục vụ theo dõi.

Cuối cùng, API trả về kết quả đầy đủ dưới dạng JSON. Frontend sẽ hiển thị kết quả bằng hiệu ứng trực quan và cho phép xuất báo cáo PDF nếu cần.

3.6.3. Luồng quên mật khẩu (OTP)

Khi người dùng quên mật khẩu, hệ thống hỗ trợ khôi phục thông qua mã OTP.

Đầu tiên, người dùng nhập email và gửi yêu cầu đến API POST /api/forgot-password. Hệ thống kiểm tra email có tồn tại hay không. Nếu hợp lệ, hệ thống sẽ tạo một mã OTP gồm 6 chữ số và gửi đến email người dùng thông qua SMTP server.

Sau đó, người dùng nhập lại mã OTP cùng với mật khẩu mới và gửi đến API POST /api/verify-otp.

Tại backend, hệ thống kiểm tra tính hợp lệ của OTP (đúng mã, còn thời hạn). Nếu hợp lệ, mật khẩu mới sẽ được mã hóa (hash) và cập nhật vào database.

Khi hoàn tất, hệ thống trả về thông báo thành công, và người dùng có thể đăng nhập lại bằng mật khẩu mới.

3.7. Sơ Đồ Use Case

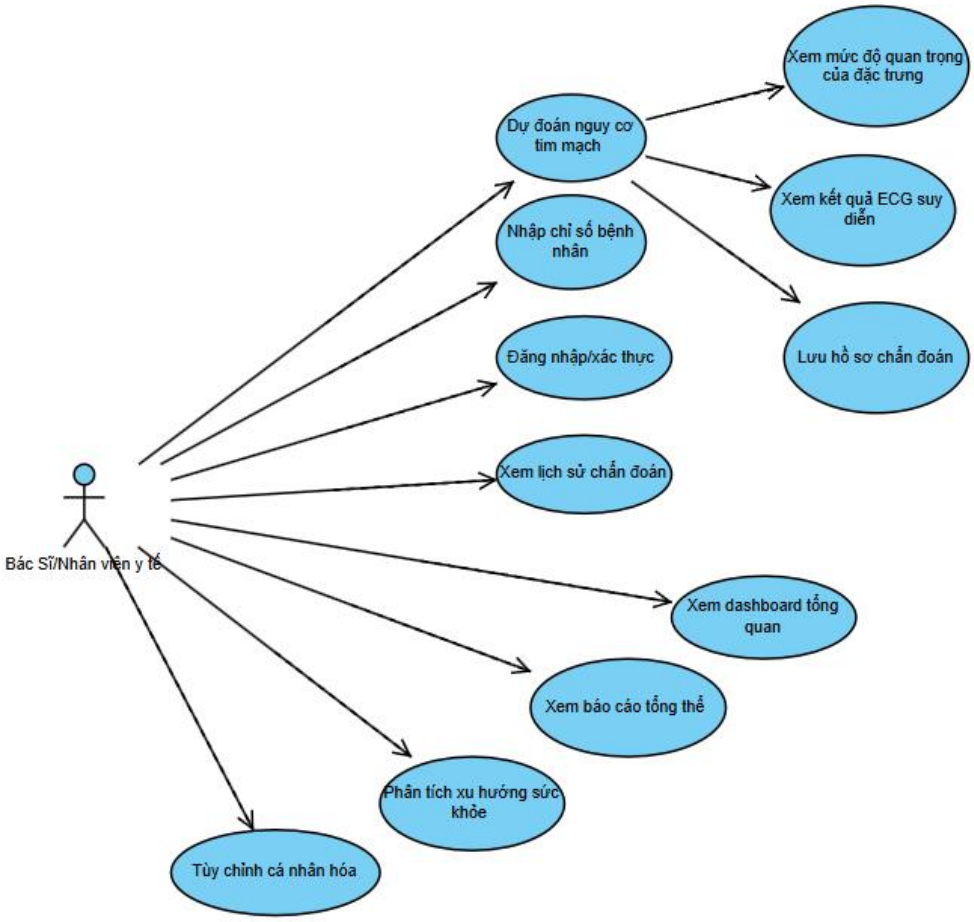

Hình 3.1: Sơ đồ USE CASE

3.8. Sơ Đồ ERD (Entity-Relationship Diagram)

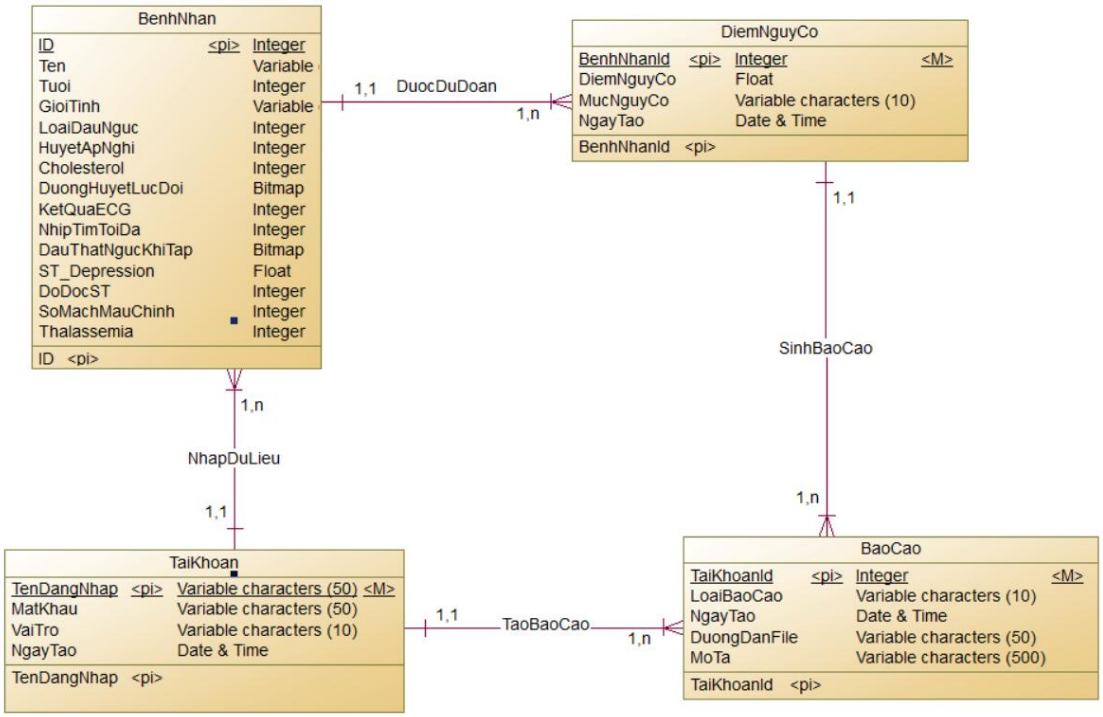

Hình 3.2: Sơ đồ ERD

3.9. Sơ Đồ DFD (Data Flow Diagram)

3.9.1. DFD Level 0 — Context Diagram

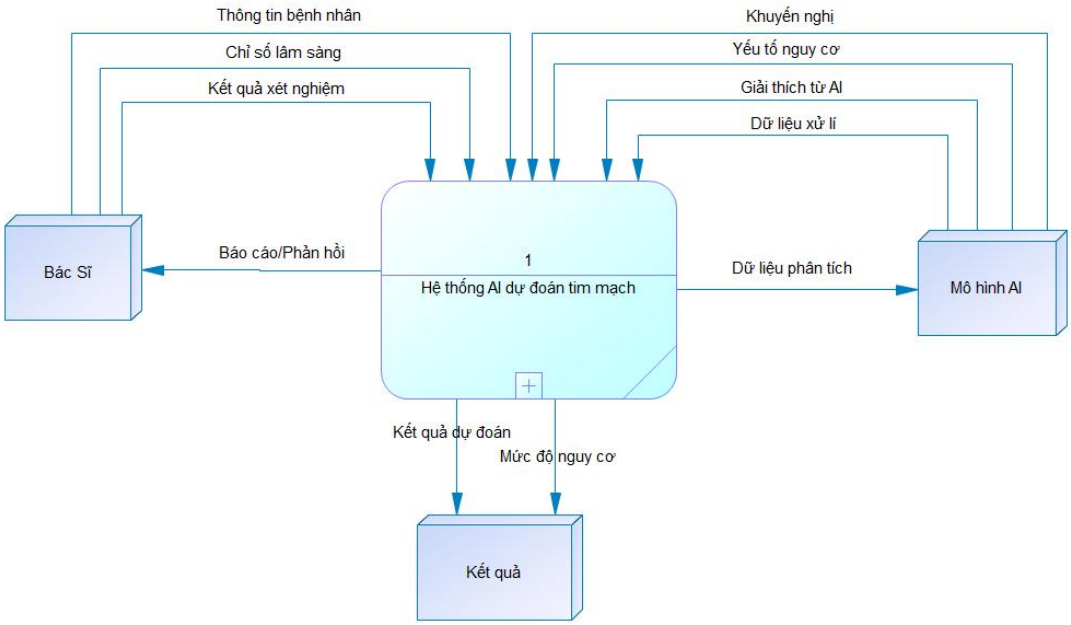

Hình 3.3: Sơ đồ DFD cấp 0

3.9.2. DFD Level 1 — Các Tiến Trình Chính

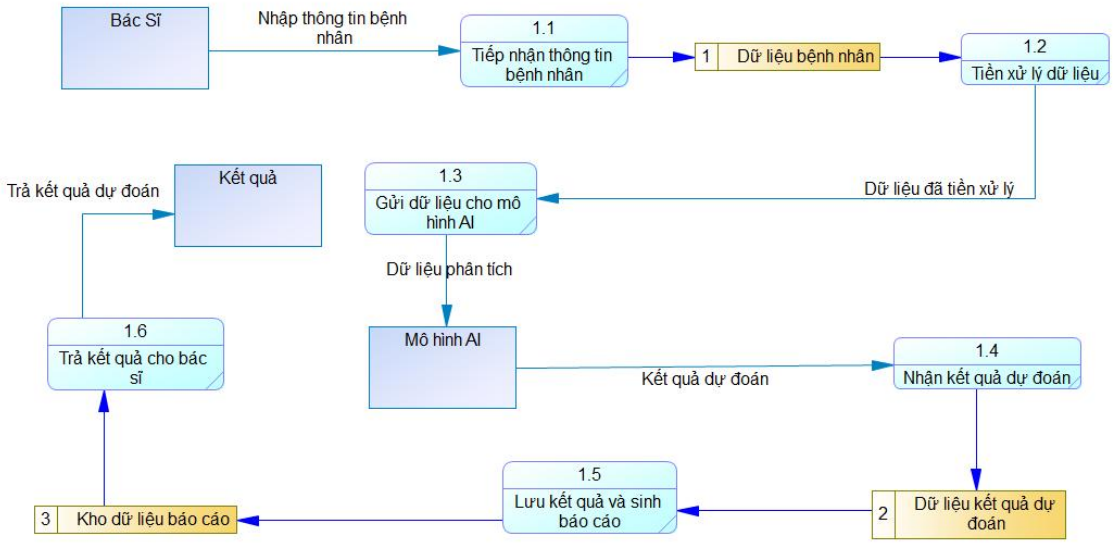

Hình 3.4: Sơ đồ DFD cấp 1

CHƯƠNG 4: GIAO DIỆN HỆ THỐNG

4.1. Trang Đăng Nhập / Đăng Ký

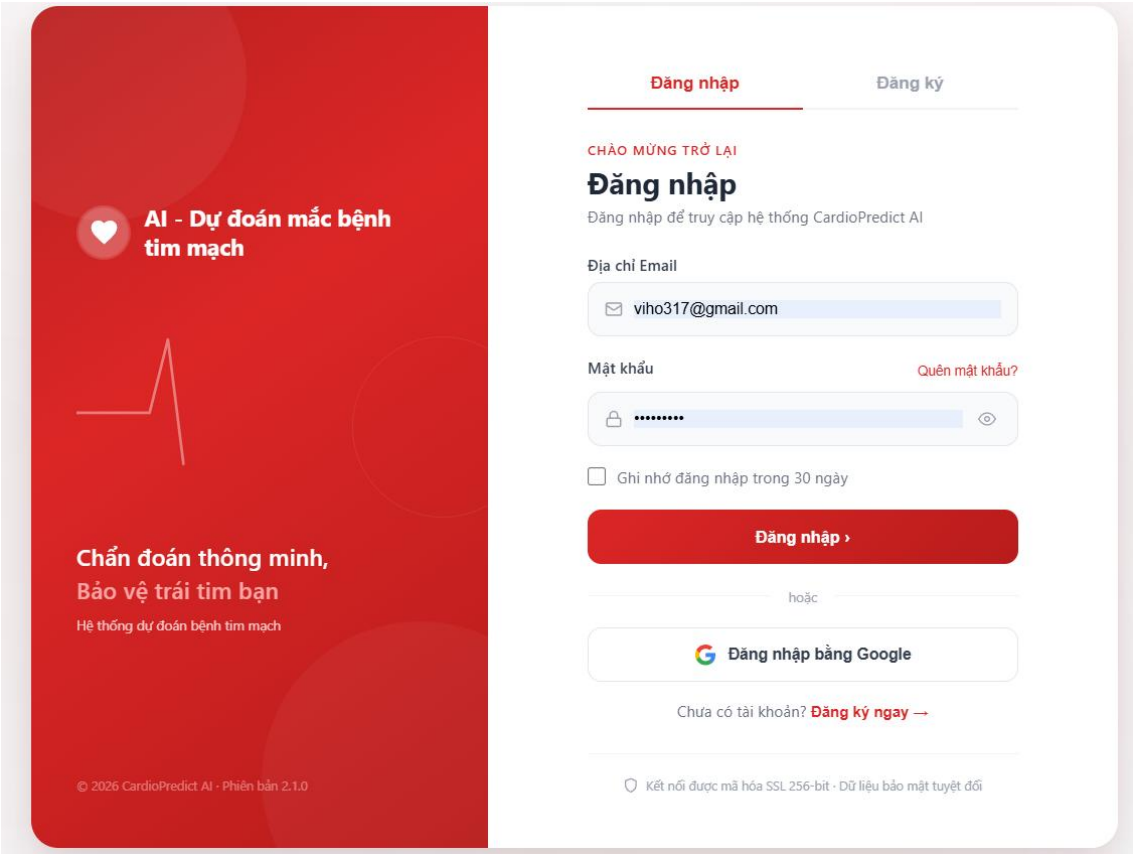

Hình 4.1: Giao diện đăng nhập

4.2. Dashboard Tổng Quan:

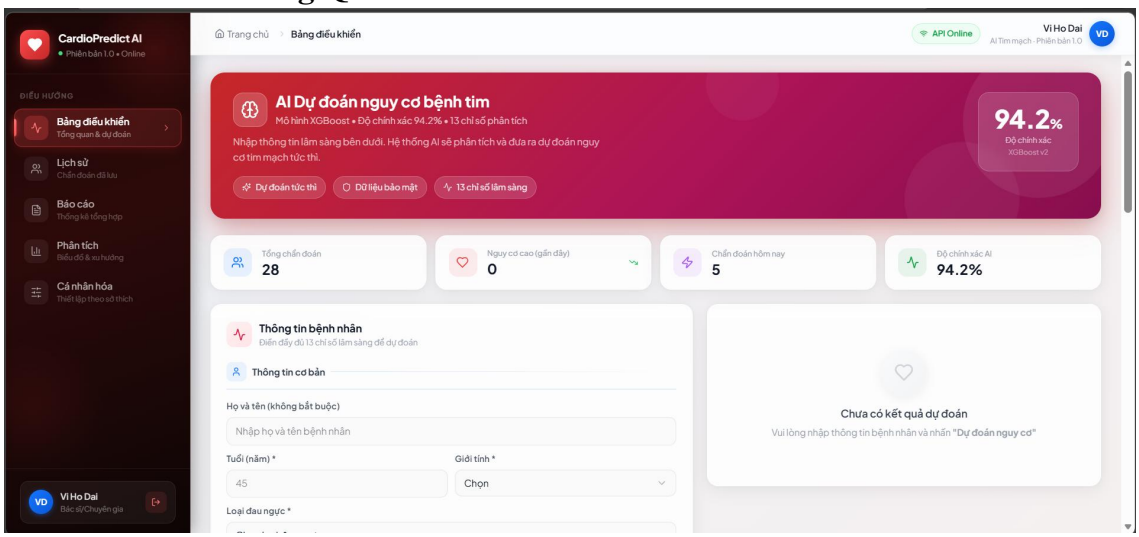

Hình 4.2 Dashboard Tổng Quan

4.3. Trang Lịch Sử Chẩn Đoán

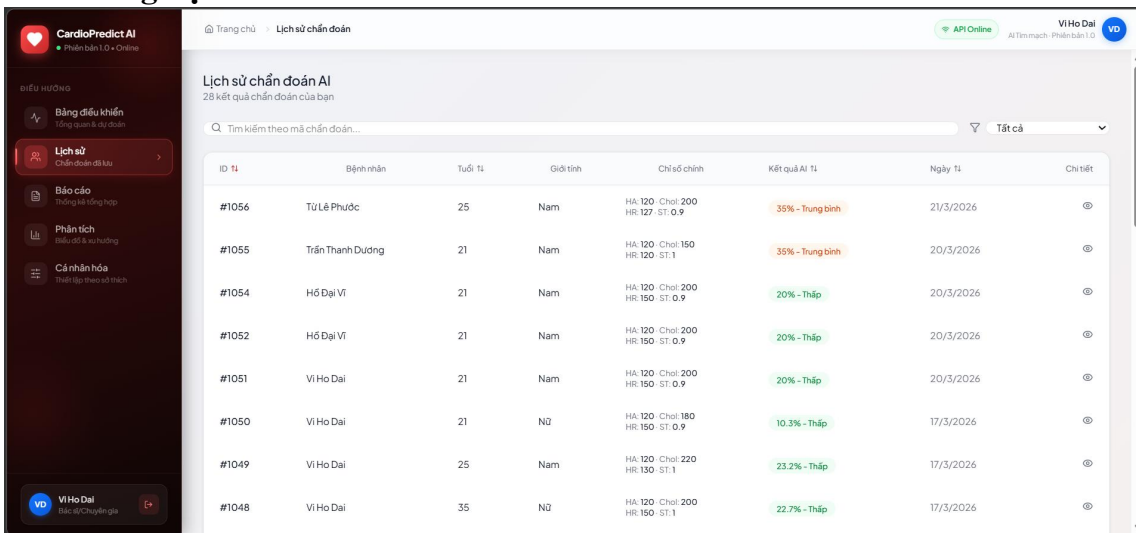

Hình 4.3 Trang Lịch Sử Chẩn Đoán

4.4. Trang Báo Cáo

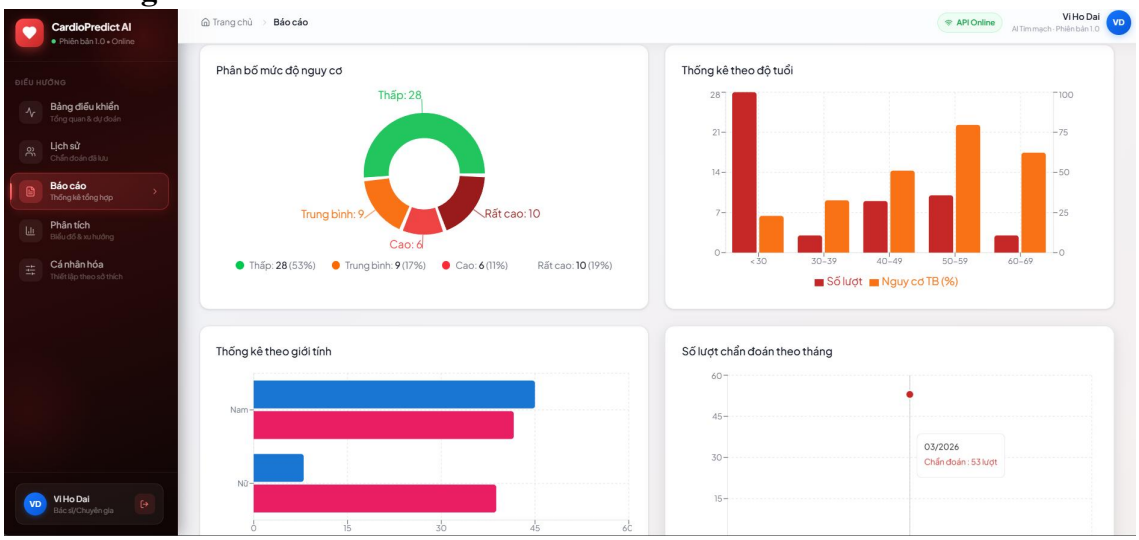

Hình 4.4 Trang Báo Cáo

4.5. Trang Phân Tích

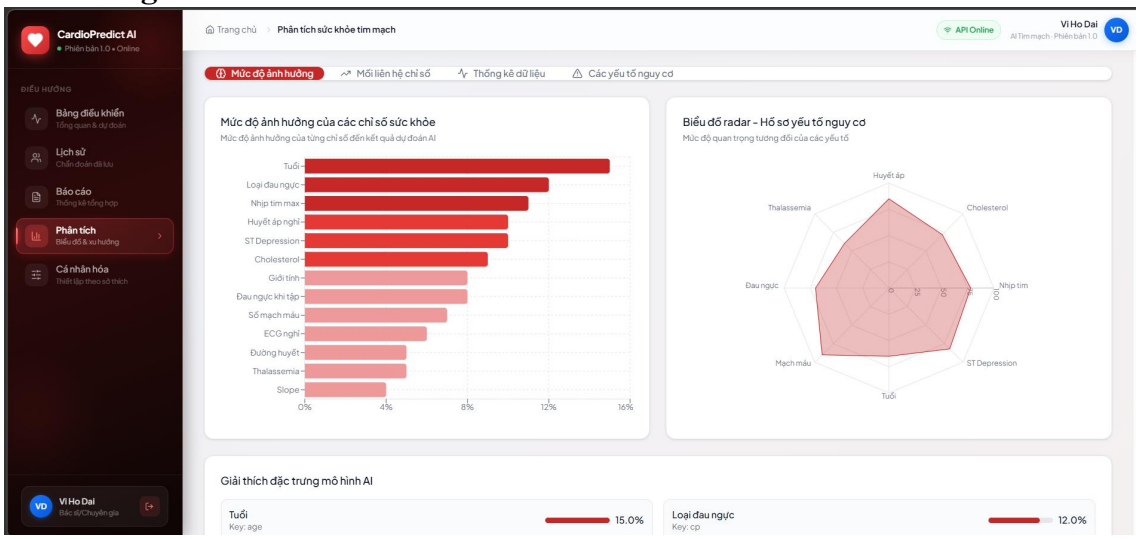

Hình 4.5 Trang Phân Tích

4.6. Trang Cá Nhân Hóa

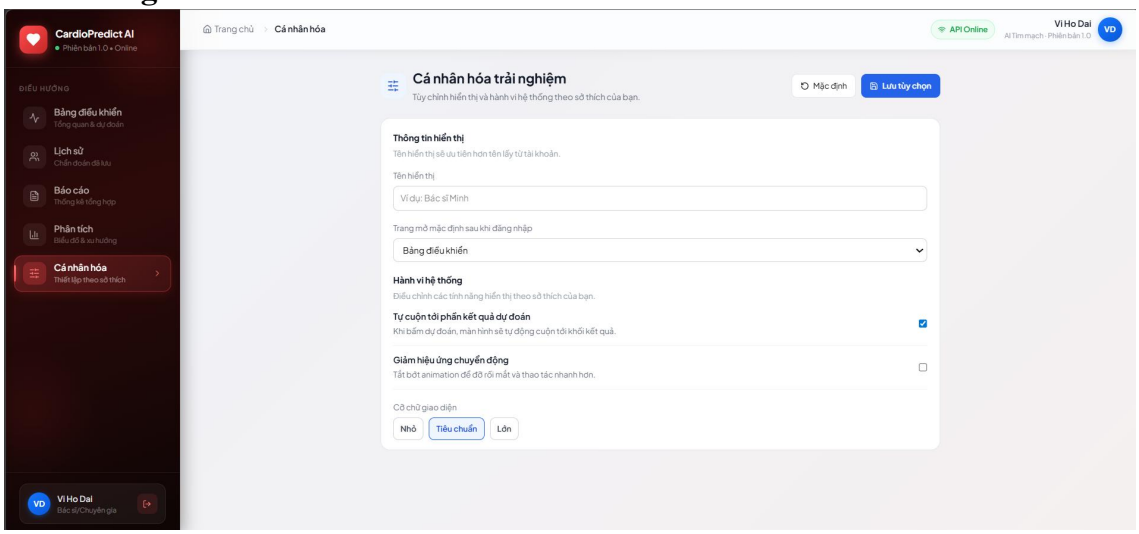

Hình 4.6 Trang Phân Tích

CHƯƠNG 5: KẾT LUẬN

5.1. Kết Quả Đạt Được

5.1.1. Kết Quả Đạt Được

Sau quá trình nghiên cứu, thiết kế và xây dựng hệ thống **CardioPredict AI – công cụ dự đoán nguy cơ bệnh tim mạch**, đề tài đã đạt được một số kết quả chính như sau:

5.1.2. Về mô hình học máy

Đề tài đã xây dựng thành công một quy trình huấn luyện mô hình hoàn chỉnh từ đầu đến cuối. Quy trình này bao gồm: tải dữ liệu, làm sạch dữ liệu (xử lý giá trị thiếu bằng giá trị trung vị và xử lý dữ liệu ngoại lai), chia dữ liệu thành tập huấn luyện và kiểm tra theo tỷ lệ 80/20, và chuẩn hóa dữ liệu đầu vào.

Hệ thống đã thử nghiệm và so sánh ba thuật toán phổ biến là Logistic Regression, Random Forest và XGBoost trên cùng một bộ dữ liệu. Kết quả cho thấy mô hình Random Forest cho hiệu suất tốt nhất trên tập kiểm tra.

Ngoài ra, đề tài còn áp dụng kỹ thuật hiệu chỉnh xác suất dự đoán để giúp kết quả đầu ra đáng tin cậy hơn, tránh việc mô hình đưa ra các dự đoán quá "tự tin".

Mô hình được đánh giá bằng nhiều chỉ số khác nhau như độ chính xác (Accuracy khoảng 76.7%), Precision, Recall, F1-Score và kiểm tra chéo (Cross Validation) để đảm bảo kết quả ổn định.

Dữ liệu sử dụng gồm hơn 5.000 mẫu bệnh nhân với 13 thông số lâm sàng quan trọng như tuổi, giới tính, huyết áp, cholesterol, nhịp tim,… Đây là các yếu tố phổ biến trong chẩn đoán bệnh tim mạch.

5.1.3. Về hệ thống Backend

Hệ thống backend được xây dựng dưới dạng **Flask REST API**, cung cấp hơn 20 API phục vụ cho các chức năng như dự đoán, đăng nhập, quản lý người dùng và giám sát hệ thống.

API dự đoán trả về nhiều thông tin hữu ích như: điểm nguy cơ, mức độ nguy cơ (thấp, trung bình, cao, rất cao), khoảng tin cậy của dự đoán, mức độ chắc chắn của mô hình, các yếu tố ảnh hưởng đến kết quả và một số gợi ý y khoa.

Hệ thống hỗ trợ nhiều phương thức xác thực như đăng nhập bằng email/mật khẩu (được mã hóa), đăng nhập bằng Google, và quên mật

khẩu qua mã OTP gửi email. Sau khi đăng nhập, người dùng sẽ sử dụng JWT token để truy cập hệ thống.

Dữ liệu được lưu trữ trong SQL Server, đảm bảo tính ổn định và khả năng mở rộng.

5.1.4. Về hệ thống Frontend

Giao diện người dùng được xây dựng bằng **React và TypeScript**, mang lại trải nghiệm hiện đại và dễ sử dụng.

Hệ thống gồm nhiều chức năng chính như:

Trang dashboard để nhập dữ liệu và xem kết quả dự đoán

Quản lý danh sách bệnh nhân

Xem biểu đồ phân tích dữ liệu

Tạo và xuất báo cáo

Theo dõi trạng thái hệ thống

Quản lý người dùng

Giao diện được thiết kế thân thiện, có hiệu ứng mượt mà và hỗ trợ hiển thị tốt trên nhiều thiết bị.

5.1.5. Về giám sát và vận hành

Hệ thống có khả năng theo dõi hoạt động theo thời gian thực như số lượng request, thời gian phản hồi và tỷ lệ lỗi.

Ngoài ra, hệ thống còn có cơ chế phát hiện khi dữ liệu đầu vào thay đổi bất thường (drift), cũng như đánh giá tính công bằng của mô hình giữa các nhóm người dùng khác nhau.

Tất cả các hoạt động quan trọng đều được ghi lại để phục vụ việc kiểm tra và phân tích sau này.

5.1.6. Về triển khai

Hệ thống đã được chuẩn bị đầy đủ để triển khai thực tế thông qua Docker, giúp dễ dàng chạy trên nhiều môi trường khác nhau.

Frontend được triển khai trên GitHub Pages, trong khi backend có thể chạy trên server riêng với cấu hình phù hợp cho môi trường thực tế.

Ngoài ra, hệ thống sử dụng Waitress để chạy backend thay cho server mặc định của Flask, giúp tăng độ ổn định khi vận hành.

5.2. Hạn Chế Của Đề Tài

Mặc dù hệ thống đã đạt được nhiều kết quả tích cực, đề tài vẫn còn một số hạn chế cần được nhìn nhận như sau:

5.2.1. Về độ chính xác của mô hình

Độ chính xác của mô hình đạt khoảng 76.7%, đây là mức chấp nhận được trong nghiên cứu nhưng vẫn chưa đủ cao để sử dụng trực tiếp trong môi trường y tế. Trong thực tế, các quyết định liên quan đến sức khỏe cần độ tin cậy rất cao, nên mô hình vẫn cần được cải thiện thêm.

Ngoài ra, số lượng dữ liệu huấn luyện còn khá hạn chế (khoảng hơn 5.000 mẫu), trong khi các hệ thống AI trong y tế thường cần dữ liệu lớn hơn rất nhiều để đảm bảo tính chính xác và ổn định. Dữ liệu hiện tại cũng chưa phản ánh đầy đủ sự đa dạng về bệnh nhân (vùng miền, thể trạng, điều kiện sức khỏe,…).

Bên cạnh đó, đề tài chưa áp dụng các kỹ thuật tối ưu nâng cao như tự động điều chỉnh tham số (tuning), tạo thêm đặc trưng mới từ dữ liệu, hoặc kết hợp nhiều mô hình để tăng hiệu quả dự đoán.

5.2.2. Về dữ liệu đầu vào

Hệ thống hiện chỉ sử dụng 13 thông số lâm sàng cơ bản. Trong thực tế, việc chẩn đoán bệnh tim mạch còn phụ thuộc vào nhiều yếu tố khác như tiền sử bệnh, chỉ số BMI, thói quen sinh hoạt, kết quả xét nghiệm và hình ảnh y khoa. Do đó, dữ liệu hiện tại vẫn còn đơn giản so với thực tế.

Ngoài ra, các thông số liên quan đến ECG trong hệ thống chỉ là giá trị ước lượng dựa trên dữ liệu nhập vào, không phải dữ liệu đo trực tiếp từ thiết bị y tế. Điều này có thể làm giảm độ chính xác của kết quả.

Một hạn chế khác là bộ dữ liệu sử dụng chủ yếu được thu thập từ nước ngoài, nên có thể chưa phản ánh đúng đặc điểm của người Việt Nam.

5.2.3. Về khả năng giải thích của mô hình

Hiện tại, hệ thống chỉ giải thích kết quả dự đoán dựa trên các quy tắc đơn giản (ví dụ: giá trị cao thì nguy cơ tăng), chưa sử dụng các phương pháp chuyên sâu như SHAP hay LIME.

Vì vậy, việc trả lời câu hỏi "tại sao mô hình lại đưa ra kết quả này" vẫn chưa thật sự rõ ràng và chưa đạt mức yêu cầu trong các ứng dụng AI trong y tế.

5.2.4. Về bảo mật và tuân thủ

Hệ thống có sử dụng JWT để xác thực người dùng, tuy nhiên việc tự triển khai thay vì dùng thư viện chuẩn có thể tiềm ẩn rủi ro khi mở rộng hệ thống.

Ngoài ra, hệ thống chưa đáp ứng đầy đủ các tiêu chuẩn bảo mật dữ liệu y tế như mã hóa dữ liệu khi lưu trữ và truyền tải, cũng như các quy định về bảo vệ thông tin cá nhân.

Chức năng OTP hiện đang lưu tạm trong bộ nhớ, nên nếu server khởi động lại thì dữ liệu sẽ bị mất. Điều này chưa phù hợp khi triển khai thực tế.

5.3. Hướng Phát Triển

Dựa trên các hạn chế và tiềm năng của hệ thống, đề tài đề xuất các hướng phát triển sau:

5.3.1. Nâng cao mô hình AI

Để cải thiện độ chính xác và khả năng ứng dụng thực tế, trong tương lai có thể phát triển mô hình theo các hướng sau:

Tăng dữ liệu huấn luyện:
Thu thập thêm dữ liệu từ các bệnh viện tại Việt Nam như Chợ Rẫy, Bạch Mai, Đại học Y Dược TP.HCM. Điều này giúp mô hình phù hợp hơn với đặc điểm người Việt, thay vì chỉ dựa vào dữ liệu nước ngoài.

Thử nghiệm Deep Learning:
Ngoài các mô hình Machine Learning truyền thống, có thể thử các mô hình như MLP, TabNet hoặc CNN để xem có cải thiện kết quả hay không.

Tạo thêm đặc trưng (Feature Engineering):
Kết hợp các đặc trưng với nhau hoặc tạo thêm các đặc trưng mới dựa trên kiến thức y khoa để giúp mô hình học tốt hơn.

Tự động tối ưu mô hình (AutoML):
Sử dụng các công cụ như Optuna, FLAML để tự động tìm tham số tốt nhất, thay vì chỉnh tay như hiện tại.

Giải thích mô hình rõ hơn:
Áp dụng thư viện SHAP để giải thích vì sao mô hình đưa ra dự đoán, giúp bác sĩ dễ hiểu và tin tưởng hơn.

5.3.2. Mở rộng dữ liệu đầu vào

Hiện tại hệ thống còn đơn giản, nên trong tương lai có thể bổ sung thêm:

Dữ liệu ECG thật:
Kết nối trực tiếp với thiết bị đo ECG để lấy dữ liệu thực, thay vì chỉ ước lượng như hiện tại.

Hình ảnh y khoa:
Kết hợp thêm ảnh siêu âm tim, X-quang để phân tích bằng AI, giúp tăng độ chính xác.

Thêm thông tin bệnh nhân:
Ví dụ: BMI, tiền sử gia đình, hút thuốc, uống rượu, stress, giấc ngủ,… vì đây đều là yếu tố ảnh hưởng đến tim mạch.

5.3.3. Cải thiện trải nghiệm sử dụng

Bác sĩ xác nhận kết quả:
Hệ thống chỉ đưa ra gợi ý, bác sĩ sẽ là người quyết định cuối cùng (confirm hoặc chỉnh sửa kết quả).

Xuất báo cáo PDF:
Tạo báo cáo chuyên nghiệp để in hoặc lưu hồ sơ bệnh án.

Kết nối hệ thống bệnh viện:
Tích hợp với phần mềm quản lý bệnh viện (HIS/EMR) để tự động lấy và lưu dữ liệu.

Phát triển ứng dụng di động:
Giúp bác sĩ có thể sử dụng hệ thống ngay trên điện thoại khi cần.

5.3.4. Tăng cường bảo mật

Mã hóa dữ liệu:
Bảo vệ dữ liệu bệnh nhân bằng mã hóa trong database và khi truyền qua mạng.

Tuân thủ quy định:
Hướng đến đáp ứng các tiêu chuẩn bảo mật y tế như HIPAA, GDPR và quy định tại Việt Nam.

Sử dụng thư viện bảo mật chuẩn:
Thay vì tự viết JWT, nên dùng thư viện như PyJWT hoặc dịch vụ như Auth0 để an toàn hơn.

5.3.5. Kiến trúc và vận hành hệ thống

Tách hệ thống thành nhiều dịch vụ (Microservices):
Ví dụ: service đăng nhập, service dự đoán,… để dễ mở rộng và bảo trì.

Tự động hóa deploy (CI/CD):
Dùng GitHub Actions để tự động test và deploy hệ thống.

Quản lý vòng đời mô hình (MLOps):
Sử dụng MLflow hoặc Kubeflow để quản lý version model, tự động train lại khi có dữ liệu mới.

Giám sát hệ thống:
Dùng Prometheus, Grafana để theo dõi hiệu năng, lỗi hệ thống.

Mở rộng hệ thống:
Triển khai trên Kubernetes để xử lý nhiều người dùng cùng lúc.

TÀI LIỆU THAM KHẢO

1.Huỳnh Võ Hữu Trí (2023), *Lập trình Python*, nxb Cần Thơ. 100 trang.

2.Bộ Y tế Việt Nam (2020). *Hướng dẫn chẩn đoán và điều trị bệnh tim mạch*. Nhà xuất bản Y học. URL: https://moh.gov.vn.

3.Nguyễn Lân Việt (2014). *Thực hành bệnh tim mạch*. Nhà xuất bản Y học, Hà Nội.

4.Phạm Nguyên Phương & Trần Thị Minh Khai (2022). "Ứng dụng học máy trong dự đoán bệnh tim mạch: Tổng quan và hướng phát triển." *Tạp chí Khoa học và Công nghệ Việt Nam*, 64(3), pp. 45–52.

5.Đỗ Trung Tuấn (2021). *Nhập môn trí tuệ nhân tạo*. Nhà xuất bản Đại học Quốc gia Hà Nội.

6.Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 3rd Edition. O'Reilly Media. ISBN: 978-1098125974.

7.Banks, A. & Porcello, E. (2020). *Learning React: Modern Patterns for Developing React Apps*, 2nd Edition. O'Reilly Media. ISBN: 978-1492051725.

8.Rajkomar, A., Dean, J., & Kohane, I. (2019). "Machine Learning in Medicine." *New England Journal of Medicine*, 380(14), pp. 1347–1358. DOI: 10.1056/NEJMra1814259.

9.Niculescu-Mizil, A. & Caruana, R. (2005). "Predicting Good Probabilities with Supervised Learning." *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, pp. 625–632.